晶科光伏发电功率与负荷预测阶段性总结

一、背景与目标

1. 背景、
   - 新能源波动性和电网稳定性矛盾加剧：光伏发电和工厂用电负荷受多种因素影响，具有强随机性和间歇性，若不能准确预测会增加碳排放和经济成本。同时传统线性模型难以捕捉此类复杂时空关联。
   - 多源异构数据融合的复杂性：预测需要整合天气预报、卫星云图、设备运行状态及经济指标等多模态数据，以提高预测精度。同时，不同区域的光伏电站因缺乏地面辐射数据，需要依赖迁移学习适配区域特征。
   - 电力市场和政策驱动：现货市场分时电价政策、绿证交易等政策，要求模型具备动态响应能力，以实现经济效益最大化和满足政策要求。
2. 目标
   - 提高预测精度与鲁棒性：采用混合架构模型，结合优化算法动态调整模态参数，解决非平稳数据问题。
   - 多时间尺度协同预测：超短期预测依赖天气预报的分钟级更新与卫星云图；中长期预测结合经济周期和季节性特性构建灰度预测模型。
   - 赋能新型商业模式：虚拟电厂通过负荷预测参与电力交易，降低购电成本；户用光伏+梯次电池项目通过调频补偿获利。绿证与碳市场联动，需预测支撑配额分配与交易策略。

二、学术界与工业界方案

1. 学术界：主要聚焦于模型创新和理论突破

- 基于深度学习的预测方法：
  - LSTM及其改进版本：通过分析与目标变量相关性较强的特征，利用降维技术和聚类分析对数据进行预处理，然后训练LSTM预测模型。
  - 门控循环单元（GRU）Transformer：利用Transformer捕捉长短期依赖关系，结合GRU进一步优化预测精度。
  - 结合注意力机制的模型：结合卷积神经网络（CNN）提取特征、双向长短期记忆网络（BiLSTM）处理时间序列和注意力机制（Attention）捕捉关键信息，提升预测性能。
- 基于数据分解的预测方法

        - 经验模态分解（EMD）和变分模态分解（VMD）：将目标变量序列分解为多个子序列，分别进行预测后再进行重构，以提高预测精度。
    - 基于相似日聚类的组合预测方法
        - 通过k-means等聚类算法将历史数据按天气类型等特征进行分类，然后对不同类别的数据分别进行预测，最后将预测结果进行组合。
    - 基于混沌理论的预测方法
        - 对光伏发电输出功率进行非线性动力学特性分析，发现其功率数据序列具有混沌特性。学者们将功率的混沌特性与各类智能算法结合，如混沌理论与RBF神经网络相结合，建立光伏发电功率超短期预测模型。

2. 工业界：注重实际应用的稳定性和工程落地

- 基于数值天气预报和卫星云图的预测
    - 利用卫星云图（如葵花8号卫星10分钟分辨率云图）和数值天气预报数据，实时监测云层的运动和变化，预测其对太阳辐照度的影响，从而预测光伏发电功率。
- 基于迁移学习的区域适配预测
    - 利用迁移学习技术，将已有的预测模型在不同区域进行适配和优化，提高模型的泛化能力和预测精度。
- 基于特征增强和多源数据融合
    - 特征增强和多源数据融合：结合气象数据（如辐照度、温度、湿度等）和历史数据，通过特征增强和多源数据融合提升预测精度。
- 基于集成学习的预测方法
    - 多模型融合：结合多种机器学习模型（如XGBoost、随机森林等）进行特征提取和预测，提升模型的泛化能力和预测精度。

三、技术路线

时序预测从其周期而言涉及三个维度：数据处理、建模方案、底模测试。精确的数据可以保障模型预测精度，避免garbage in, garbage out的现象；光伏发电功率与负荷的序列可能存在突变型强、偶现非平稳的随机波动等问题，因此有必要对原序列进行分解预测，或者纳入异常检测等机制构建不同条件下的混合预测模型；预测模型的基础是底座模型，或可采用系统级联动的机器学习模型（包含集成学习），也可使用预训练的时序大模型进行few shot或微调预测。因此，时序预测的研究将根据以上三个维度进行拆分，分别进行迭代并进行交叉验证。

1. 数据处理

数据处理的部分主要涉及以下部分，每一个细分项都需要探索最优的做法，并固化为pipeline：

1.1 数据清洗与修复

- 缺失值填补：采用线性插值、季节性均值或基于邻域（KNN）的填充方法，对传感器断点数据修复。
- 异常检测与处理：通过3σ原则、孤立森林或动态阈值（如滑动窗口百分位数）识别离群点，结合业务逻辑判断是否修正或剔除。现有做法是将异常值置为空，并根据不同特征的特性选择不同方法进行填充。
- 数据平滑：对高频噪声数据使用Savitzky-Golay滤波器或小波变换，保留趋势特征的同时降低随机波动。

1.2 特征工程探索

i. 周期与趋势分解

- STL分解（Seasonal-Trend decomposition using Loess）：将序列拆分为季节项、趋势项和残差项，尤其适用于非固定周期数据。
- 傅里叶变换：检测隐含周期信号，通过频谱分析确定主周期频率，辅助后续特征工程。
- 差分平稳化：针对非平稳序列，进行一阶/季节性差分（如ARIMA中的d参数选择），并通过ADF检验验证平稳性。
- 多尺度分解：采用经验模态分解（EMD）和变分模态分解（VMD）将目标变量序列拆分为趋势项、季节项、残差项，分别建模以降低复杂度

ii. 特征增强

- 滞后特征构建：生成历史窗口的滞后变量（如t-1, t-24），并计算滚动统计量（均值、方差）。
- 外部变量融合：引入温度、节假日等协变量，通过Granger因果检验筛选有效特征。
- 时域到频域转换：提取小波系数、Hurst指数等非线性特征，增强模型对复杂模式的捕捉能力。
- 构造新特征：阅读文献搜集与目标变量有强相关性的特征

1.3 数据生成与增强

- 上采样：三次样条插值。这项对于天气数据而言尤其重要。
- LLM驱动的数据插补：基于GPT-4等LLM，从知识库中生成与气象事件关联的文本描述（如“台风路径偏移”），同步生成对应的辐照度、风速数值序列，构建时间连续的多模态数据集

2. 建模方案

2.1 原始序列

对原始序列进行平滑后，再直接建模，是目前的工业界的主流方案。

2.2 分解序列单独建模

- 在与外部交流发现，可以将平滑后的原始序列分解为上包络线和下包络线，并分别建立预测模型，最后通过调整权重将两个预测模型的预测结果加权。此方法可有效减少波峰段的误差。
- 对平滑后的序列用EMD或VMD分解，提取主要的成分，并分别建立预测模型。
- 使用常用的时序分解方法，将平滑后的原始序列分解为趋势项、季节项和残差项，并分别建模。

2.3 混合机制

由于影响负荷的主要为下游的用电行为，而行为的突发改变将导致原有预测模型失效，将对策略产生重大影响和产生经济损失。因此可考虑在时间维度上建立多层预测模型，配合异常识别（时序分类）的归类启用不同的预测模型进行预测。

具体而言，正常情况下，日前负荷预测模型势必将在日内运行时产生误差，而该误差将由日内负荷预测模型（假定为预测未来1小时，15分钟频率）进行修正。然而，假设日内负荷的模式与正常情况不符时（如工厂提前放假、订单激增等），原日内负荷预测模型将失效，需由异常检测模型及时识别并更换预测模型或者业务逻辑。

2.4 多模型融合

上述的三条路线实际可相互结合使用，同时，从底模的使用而言，可考虑使用基础模型（ARIMA、时序大模型等）拟合主流趋势，使用深度学习/机器学习模型学习残差的非线性模式。

3. 底模测试

3.1 传统统计模型

- SARIMA：通过ACF/PACF确定参数阶数，季节性差分处理周期效应，适合线性关系主导的场景。
- 状态空间模型：如结构时间序列（Prophet），显式建模节假日效应和变点检测。
- GARCH族：针对时序的波动聚集性，建模条件异方差现象。

3.2 机器学习方法

- 树模型特征组合：LightGBM/XGBoost处理高维特征，通过早停策略防止过拟合，并输出特征重要性。
- 核方法回归：高斯过程（GP）建模不确定性，适用于小样本且需概率输出的场景。
- 集成策略：Stacking多层模型（如第一层LSTM+Prophet，元模型用线性回归），提升鲁棒性。

3.3 深度学习架构

- RNN变体：BiLSTM捕捉双向依赖，加入Attention机制聚焦关键时间步。
- TCN时域卷积：空洞卷积扩大感受野，并行结构加速训练，优于RNN的长程依赖处理。

- Transformer革新：TSMixer、TFT。

3.4 预训练时序大模型

以chronos、timesfm为代表的开源时序大模型，将持续跟踪。

四、数据方案

1. 数据清洗与修复

目标：预测频率为5分钟的光伏发电功率

已有数据为小时级别，需要将小时级数据进行上采样

- 辐射数据：

  针对昼夜辐射特性差异，我们采用分段插值策略：白天辐射变化剧烈，采用高精度插值结合抗混叠滤波；夜间辐射稳定，采用简单填充以保证数据连续性和稳定性。同时，通过物理约束确保数据合理性，包括阈值划分防止夜间异常高值、clip操作保证非负性，以及在过渡区采用线性插值避免过冲。此外，抗混叠设计采用三次样条插值结合Savitzky-Golay滤波，平衡曲线平滑度与细节保留，确保最终结果的可靠性和稳定性。

- 天气数据：

  针对不同气象数据的特性，我们采用差异化的处理策略以确保数据的准确性和物理合理性。气温处理采用线性插值保持小时级趋势，同时结合1小时窗口（12个5分钟点）的滚动平均，消除突变毛刺。湿度处理通过线性插值结合边界约束，强制将湿度值限制在[0,100]范围内，防止插值产生超范围值。气压处理利用三次样条插值捕捉其连续变化特性，适用于缓慢变化的物理量。降水量处理采用随机分布算法，将每小时降水量随机分配到1-2个5分钟时段，确保小时累计量不变，同时通过指数对齐修复保证时间连续性。风场分量处理通过矢量分解插值，将风场分解为U/V分量后分别插值，再重组为风向和风速，确保物理一致性。地面风速处理采用线性插值结合非负约束，保证风速的物理合理性。风向处理使用三角函数优化角度插值，避免360°跳变问题，并将结果归一化到0-360度范围内。这些方法结合了插值、约束和优化技术，确保气象数据在时间序列上的连续性、物理合理性和细节保留。

2. 特征工程

已有特征：发电功率、气温、湿度、气压、降水量、纬向风、经向风、地面风速、风向、地表水平辐射、法向直接辐射、散射辐射

构造特征：

	描述
HH	时间戳中的小时部分

Wind_Speed_Vector	合成实际风速，反映风的整体强度对光伏板散热、机械稳定性的影响
Cooling_Rate	表征风速与温度的对抗效应：风速越大散热越强，高温可能降低光伏效率
direct_ratio	直射辐射占比： 接近1表示直射光主导（晴朗天气） 接近0表示散射光主导（多云/阴天）
temp_diff	温度差分，反映温度变化的瞬时性（如冷锋过境、云层突变），可能影响光伏板工作温度稳定性
humidity_temp_interaction	温湿度交互效应：高温高湿环境可能加剧光伏板表面结露/污垢沉积
altitude	太阳高度角 决定光照入射角（0°~90°） 高度角越大，单位面积接收的辐射能量越高
azimuth	太阳方位角： 反映太阳在水平面的方向（0°~360°） 与光伏板朝向的匹配度影响有效受光面积

五、结果验证

原计划在1分钟/5分钟的时间维度上建立预测模型，然而原始数据波动较大，且可获取的天气数据一般为小时级别，插值后的误差较大，严重影响预测效果。考虑到业内普遍在15分钟维度上展开研究，且多数地区的电价更新频率也为15分钟，因此将数据重构为15分钟的采样频率后再进行建模。

1. 预测未来一小时（4个点）

1.1 光伏发电功率

1.1.1 2024年11月22日

```
日期: 2024-11-22
决定系数R²: 0.9981
均方根误差RMSE: 61.6671
```

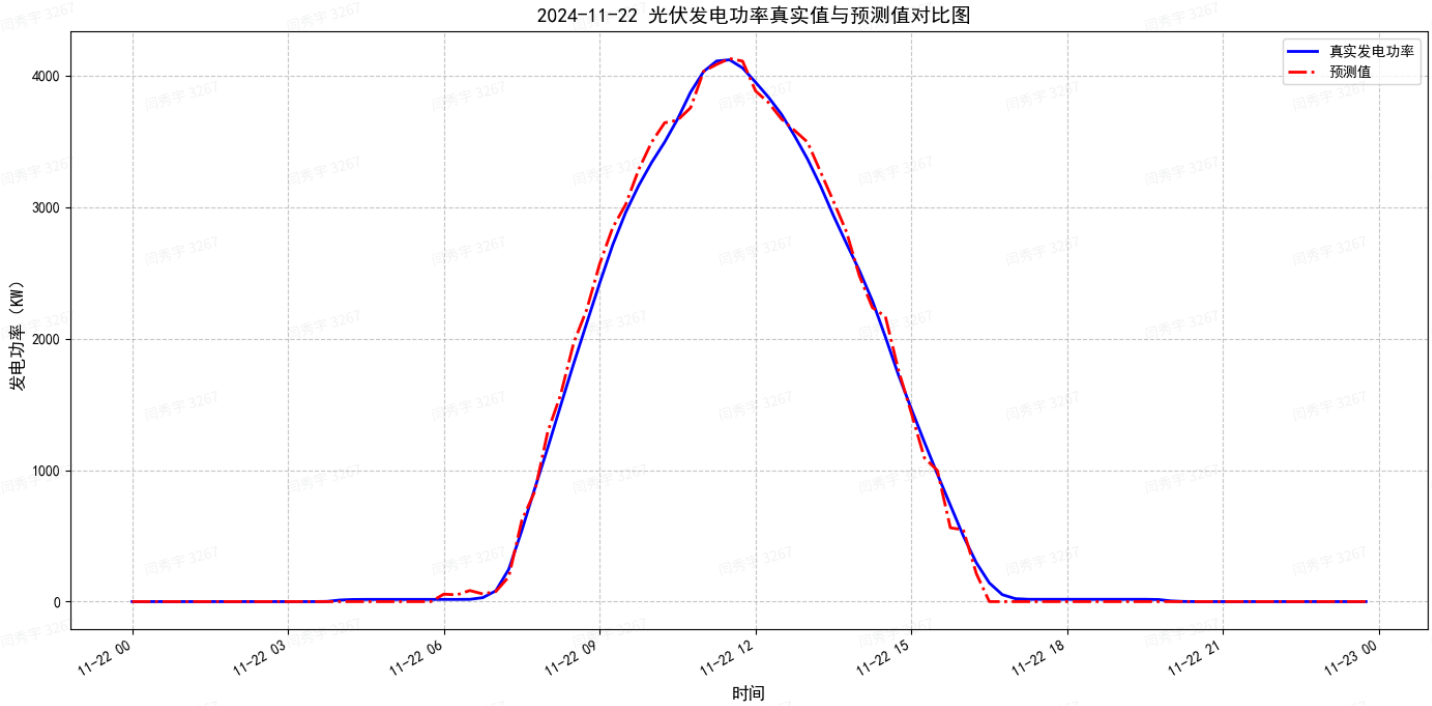

- 4:00~7:00

```
时间: 2024-11-22 4-7
决定系数R²: -50.4409
均方根误差RMSE: 29.1105
```

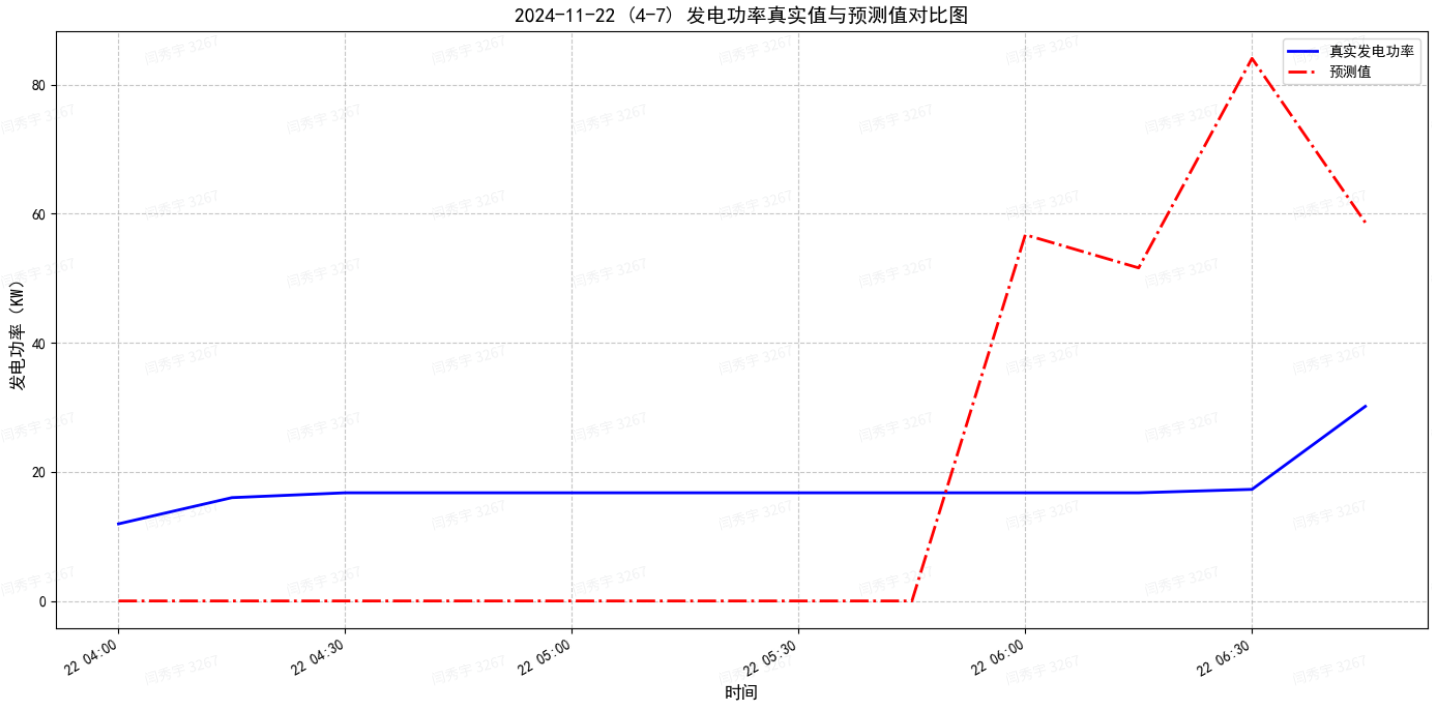

- 7:00~16:00

```
时间: 2024-11-22 7-16
决定系数R²: 0.9940
均方根误差RMSE: 94.1453
```

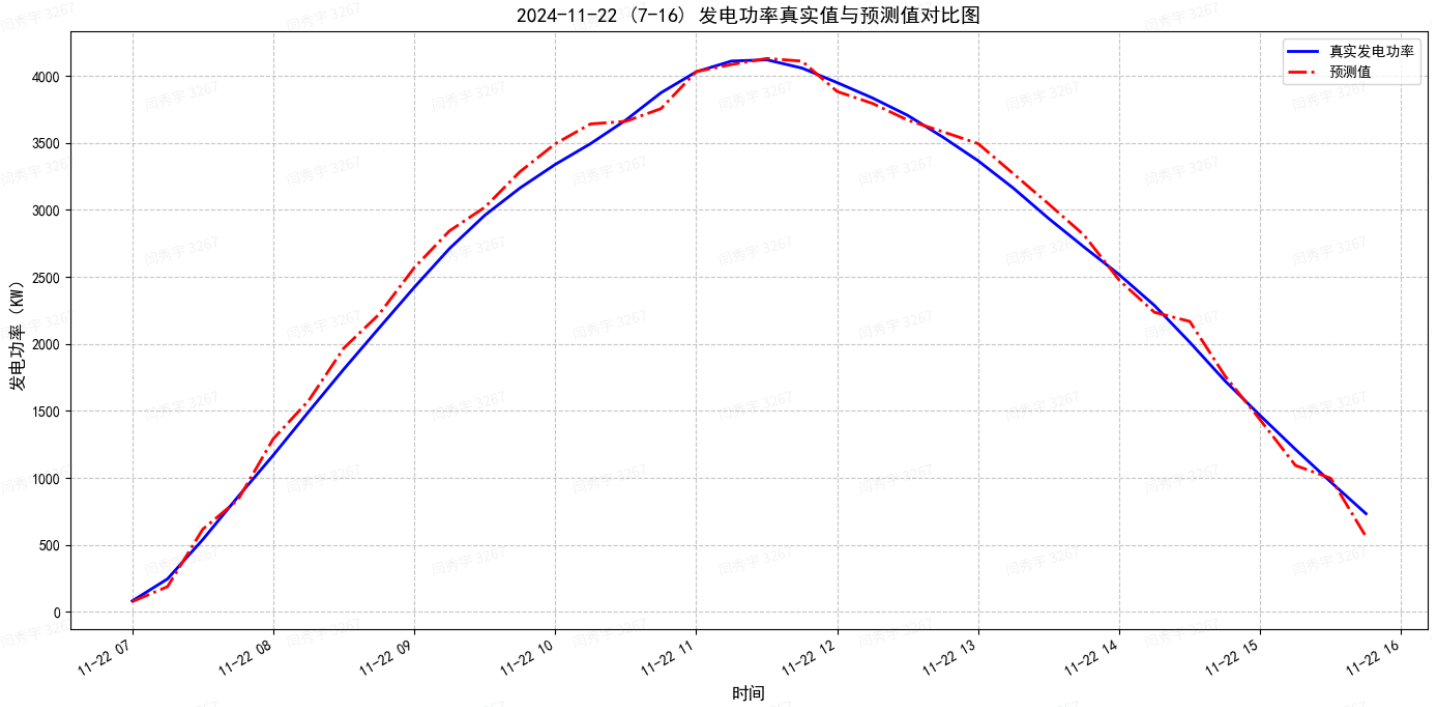

- 16:00~20:00

```
时间: 2024-11-22 16-20
决定系数R²: 0.8686
均方根误差RMSE: 47.2990
```

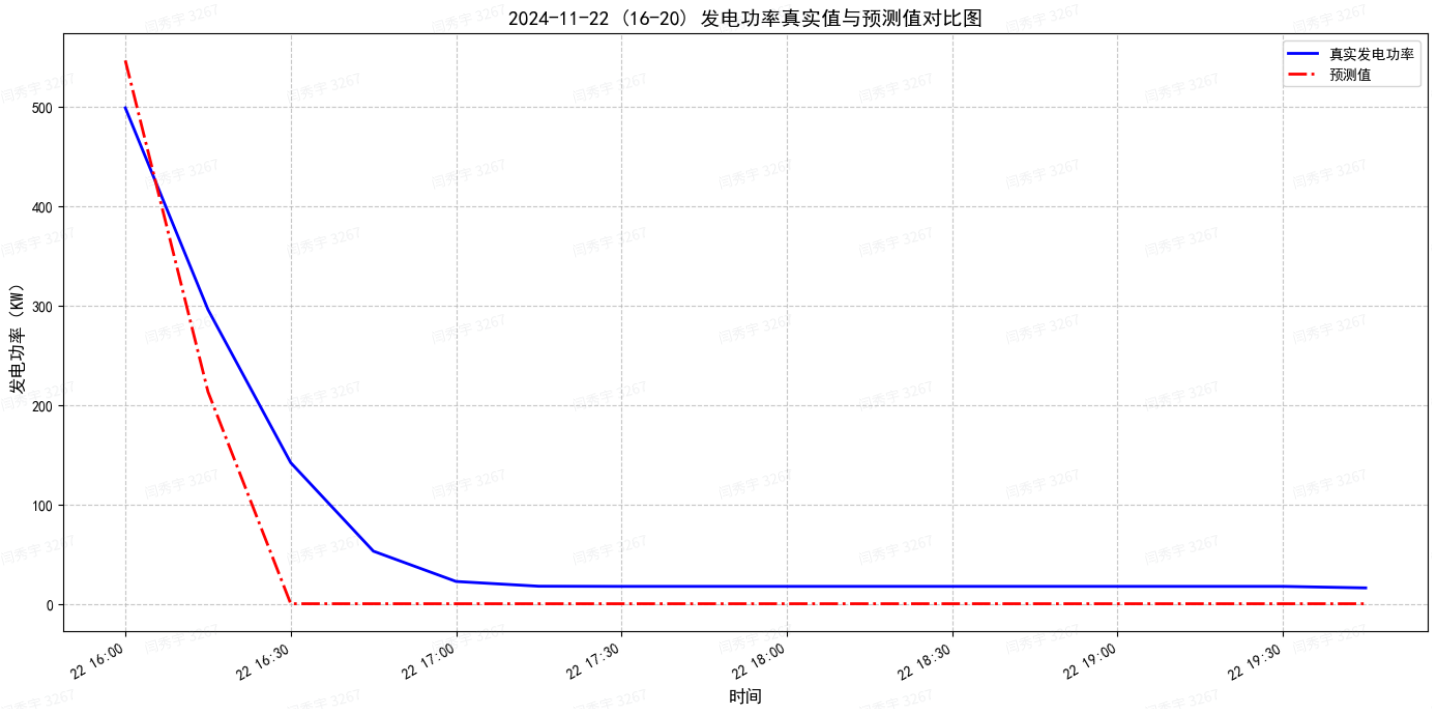

1.1.2 2024年11月27日

```
日期: 2024-11-27
决定系数R²: 0.9889
均方根误差RMSE: 151.4738
```

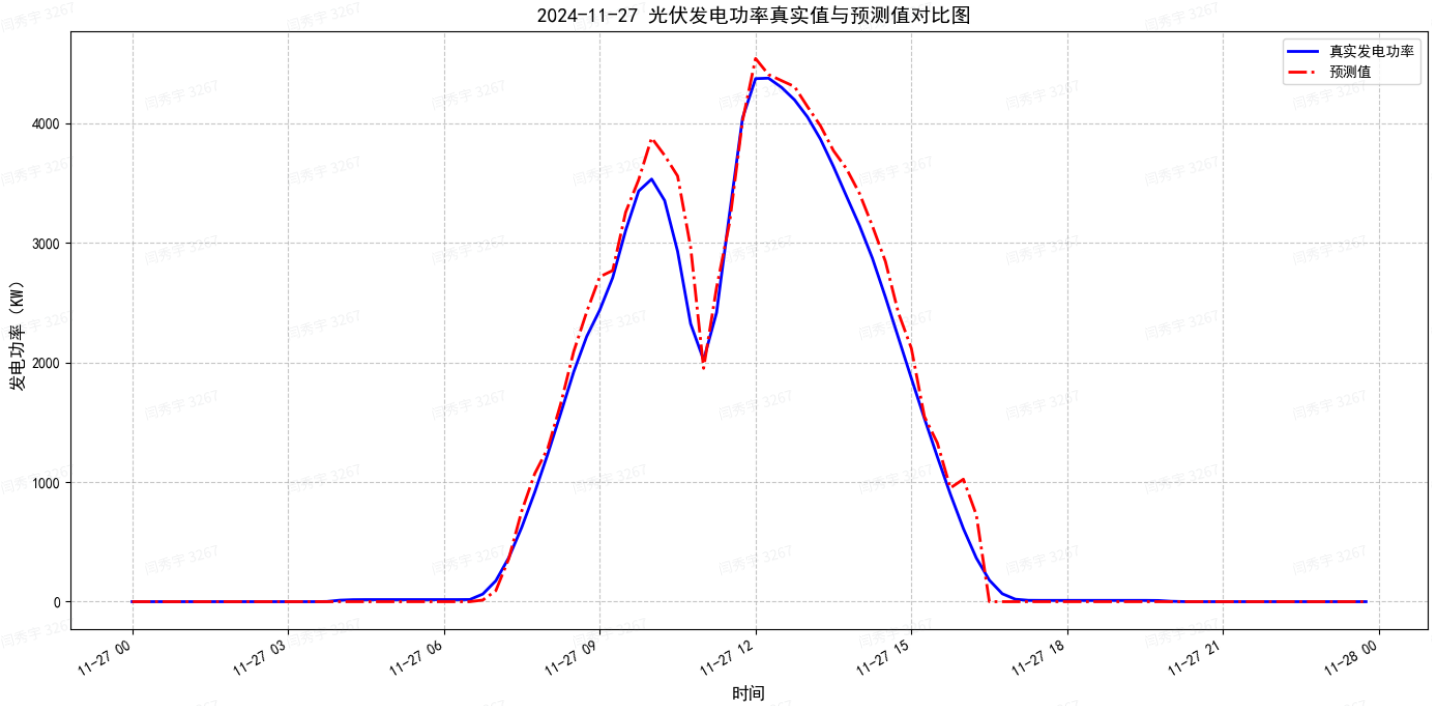

- 4:00~7:00

```
时间: 2024-11-27 4-7
决定系数R²: -1.7539
均方根误差RMSE: 21.6125
```

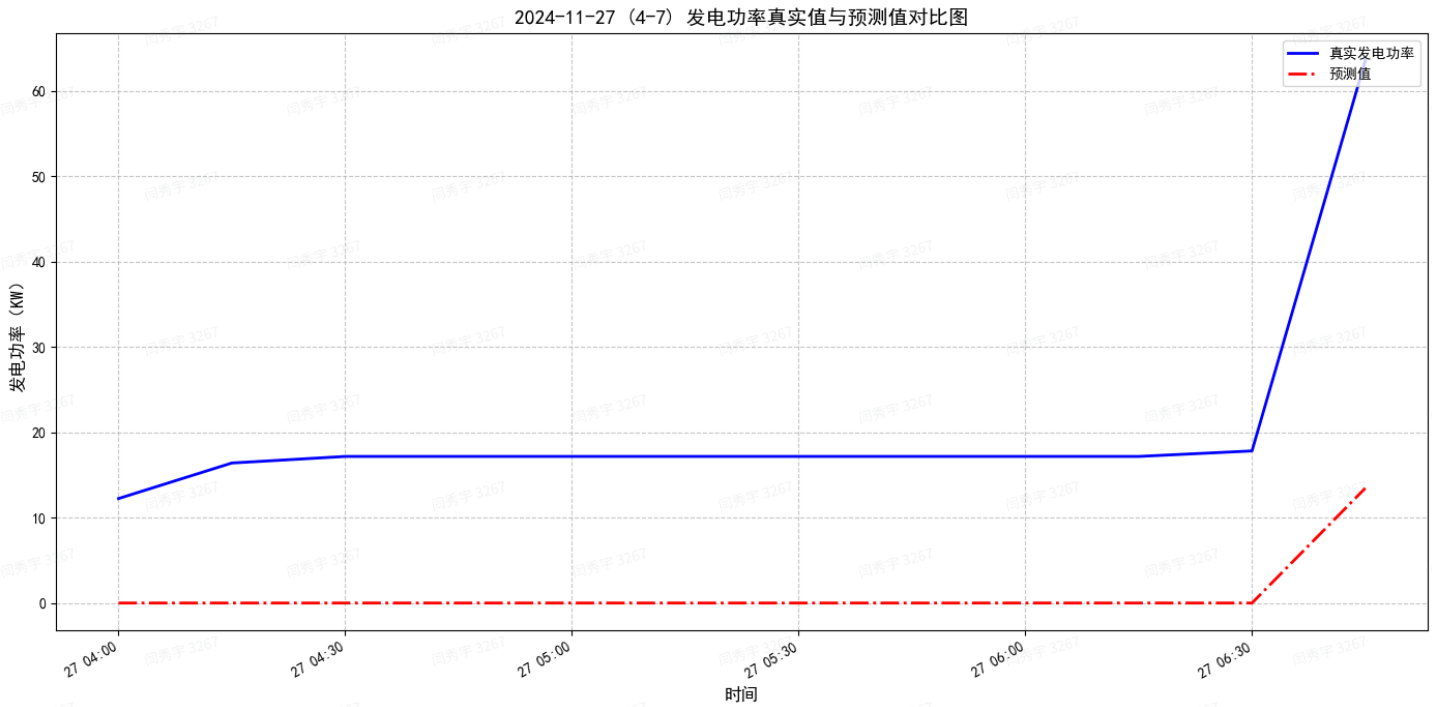

- 7:00~16:00

```
时间: 2024-11-27 7-16
决定系数R²: 0.9634
均方根误差RMSE: 227.1846
```

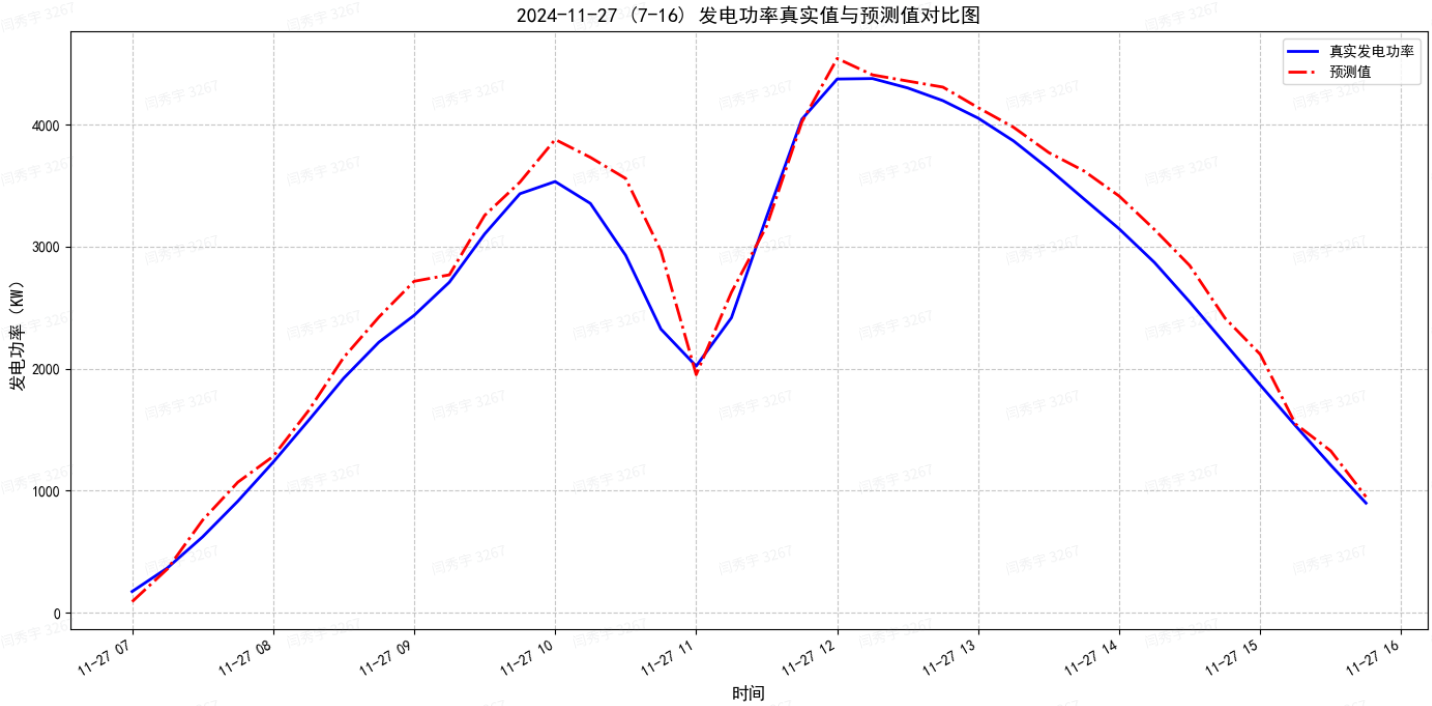

- 16:00~20:00

```
时间: 2024-11-27 16-20
决定系数R²: 0.2109
均方根误差RMSE: 145.5535
```

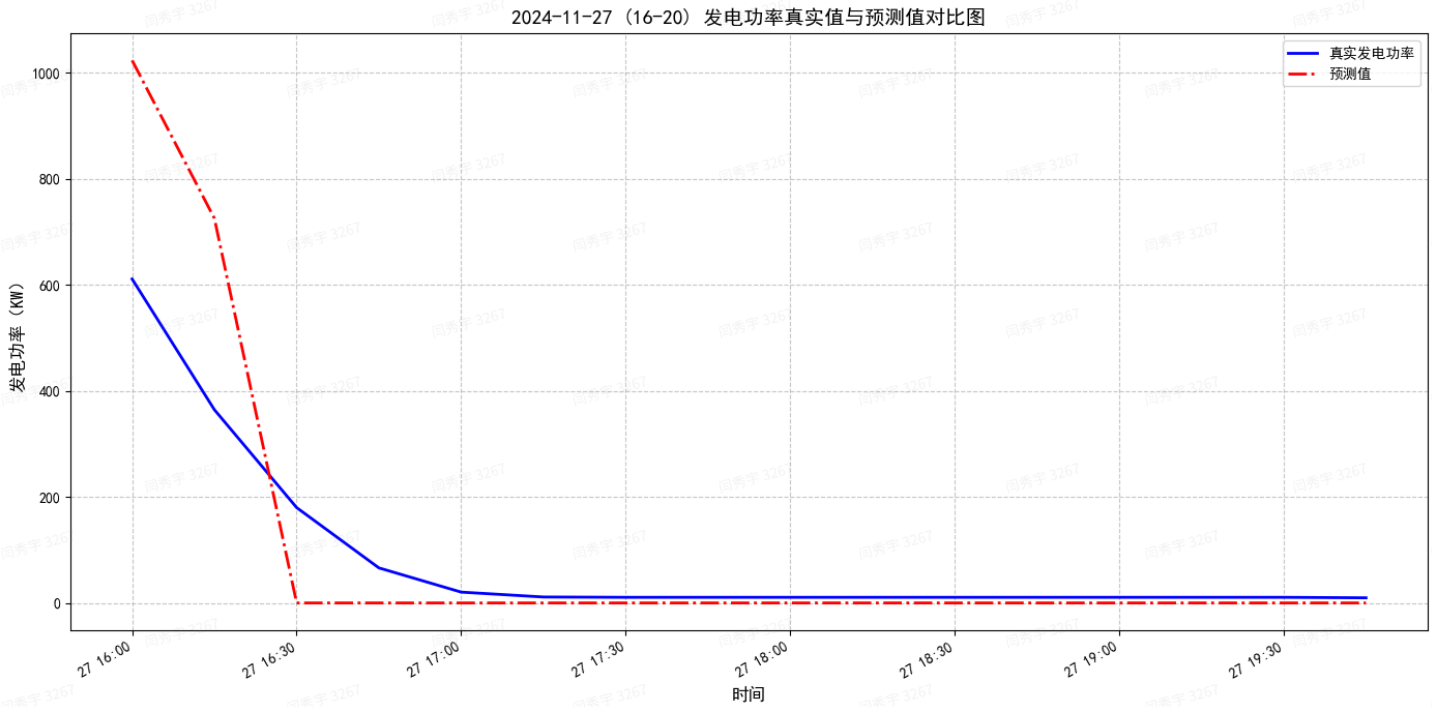

1.1.3 2024年11月29日

```
日期: 2024-11-29
决定系数R²: 0.9898
均方根误差RMSE: 162.7947
```

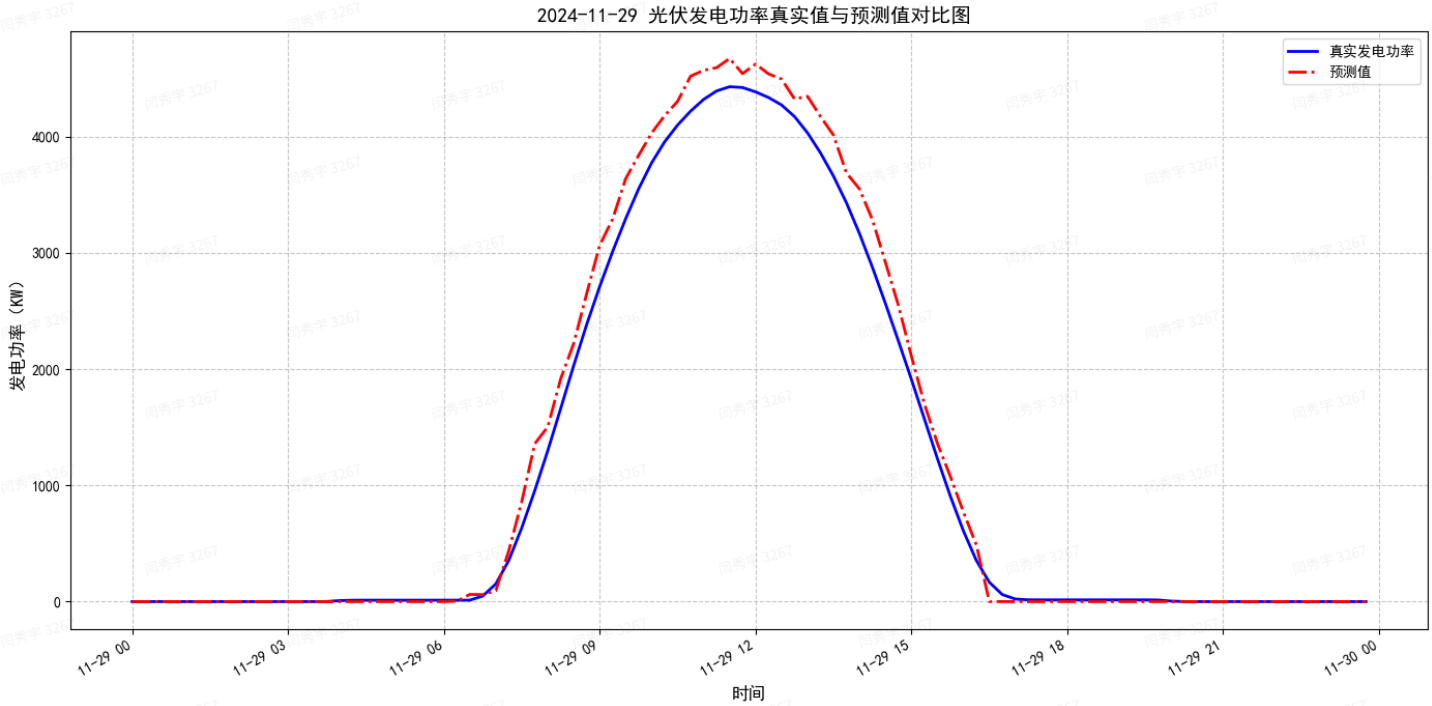

- 4:00~7:00

```
时间: 2024-11-29 4-7
决定系数R²: -2.1942
均方根误差RMSE: 18.1075
```

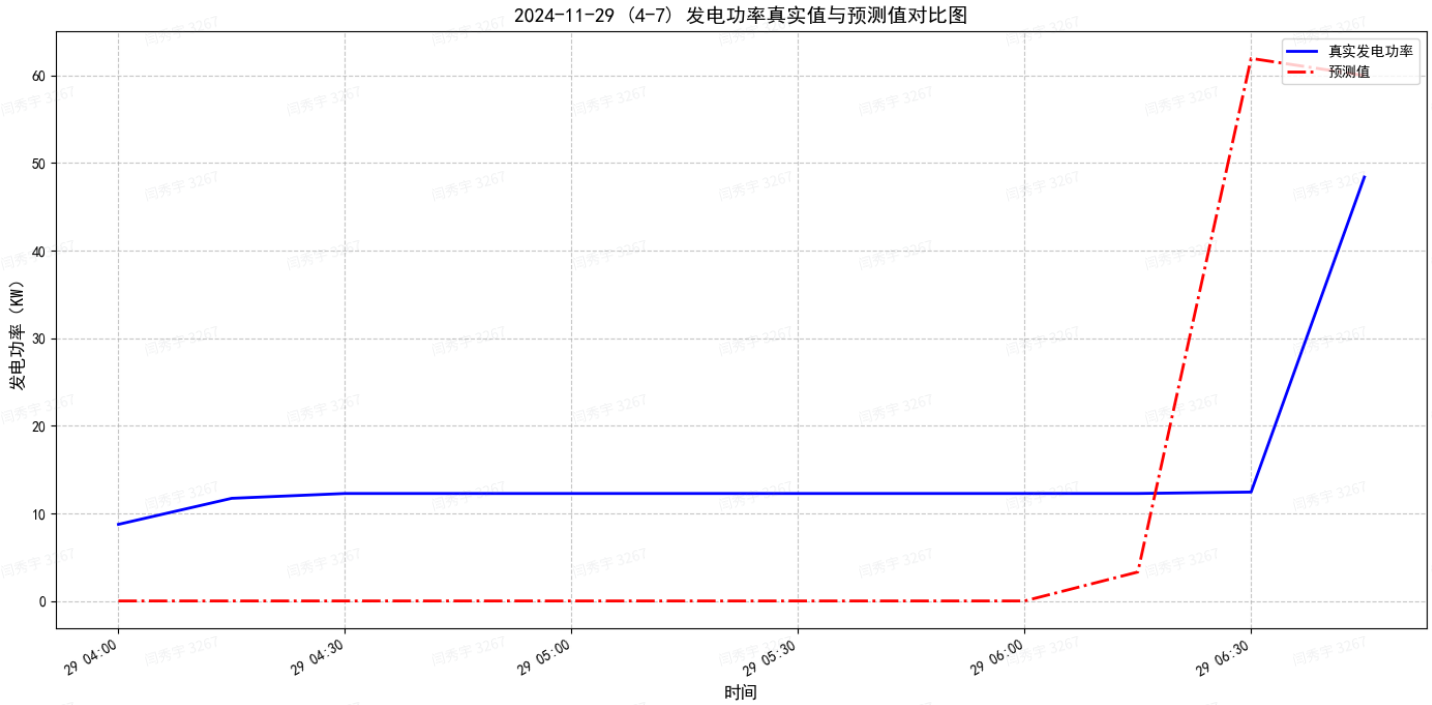

- 7:00~16:00

```
时间: 2024-11-29 7-16
决定系数R²: 0.9613
均方根误差RMSE: 261.4751
```

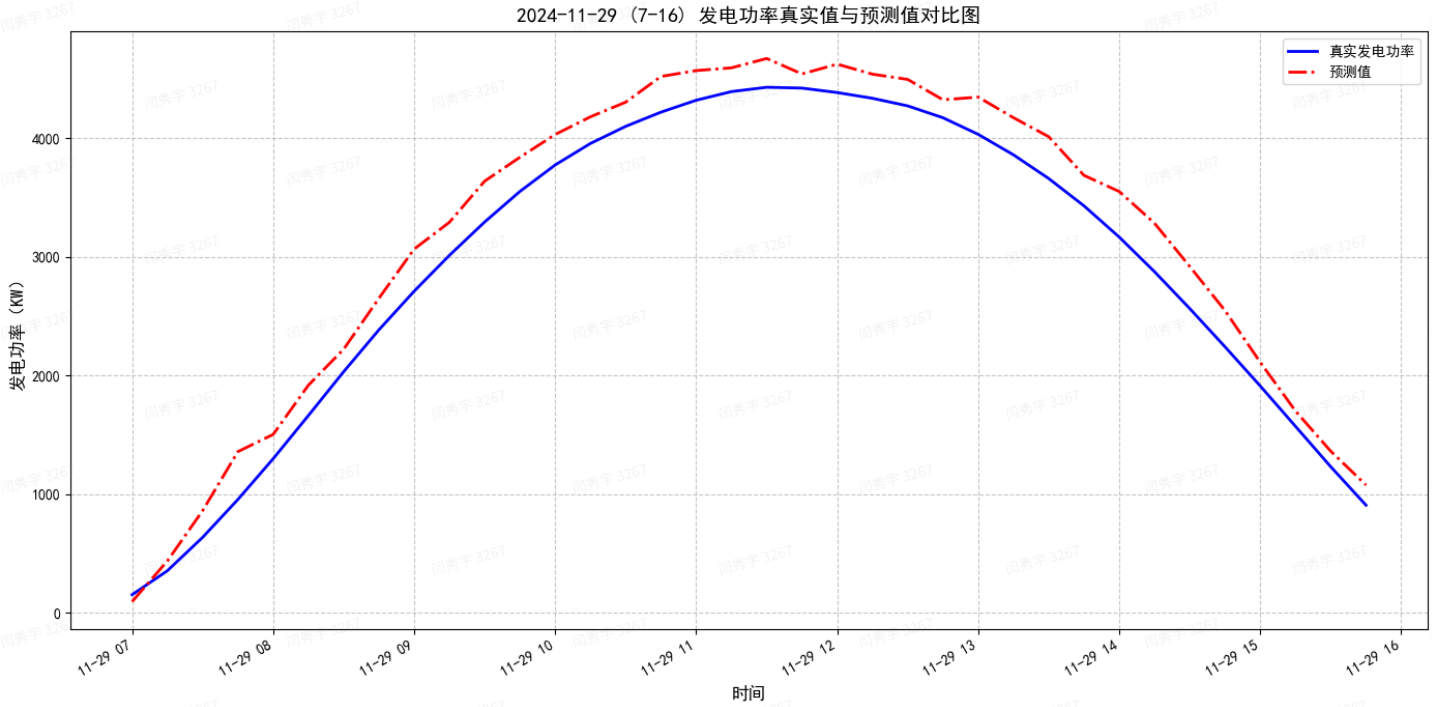

- 16:00~20:00

```
时间: 2024-11-29 16-20
决定系数R²: 0.8083
均方根误差RMSE: 70.2486
```

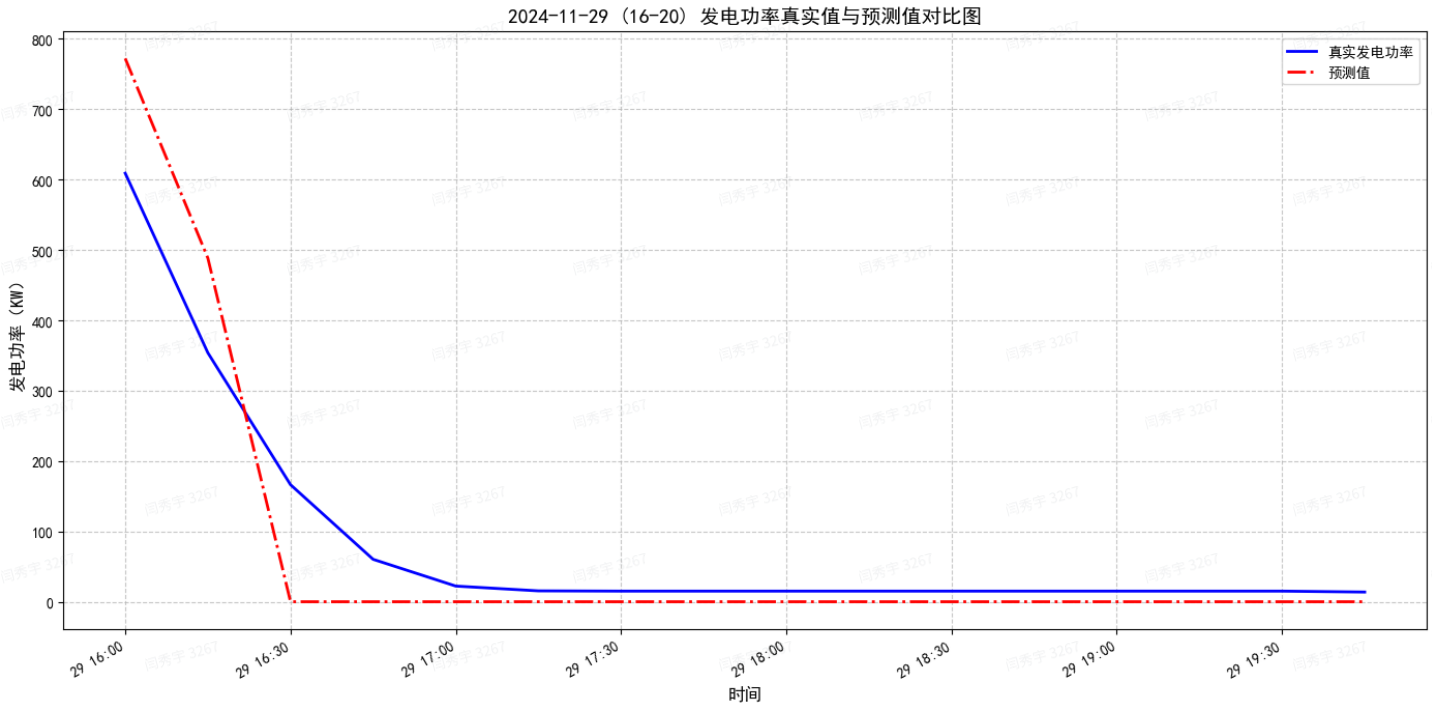

1.2 工厂用电负荷

1.2.1 工作日

- 正常工作日：2025年2月9日

```
日期: 2025-02-09
决定系数 R²: 0.9980
均方根误差RMSE: 335.6724
```

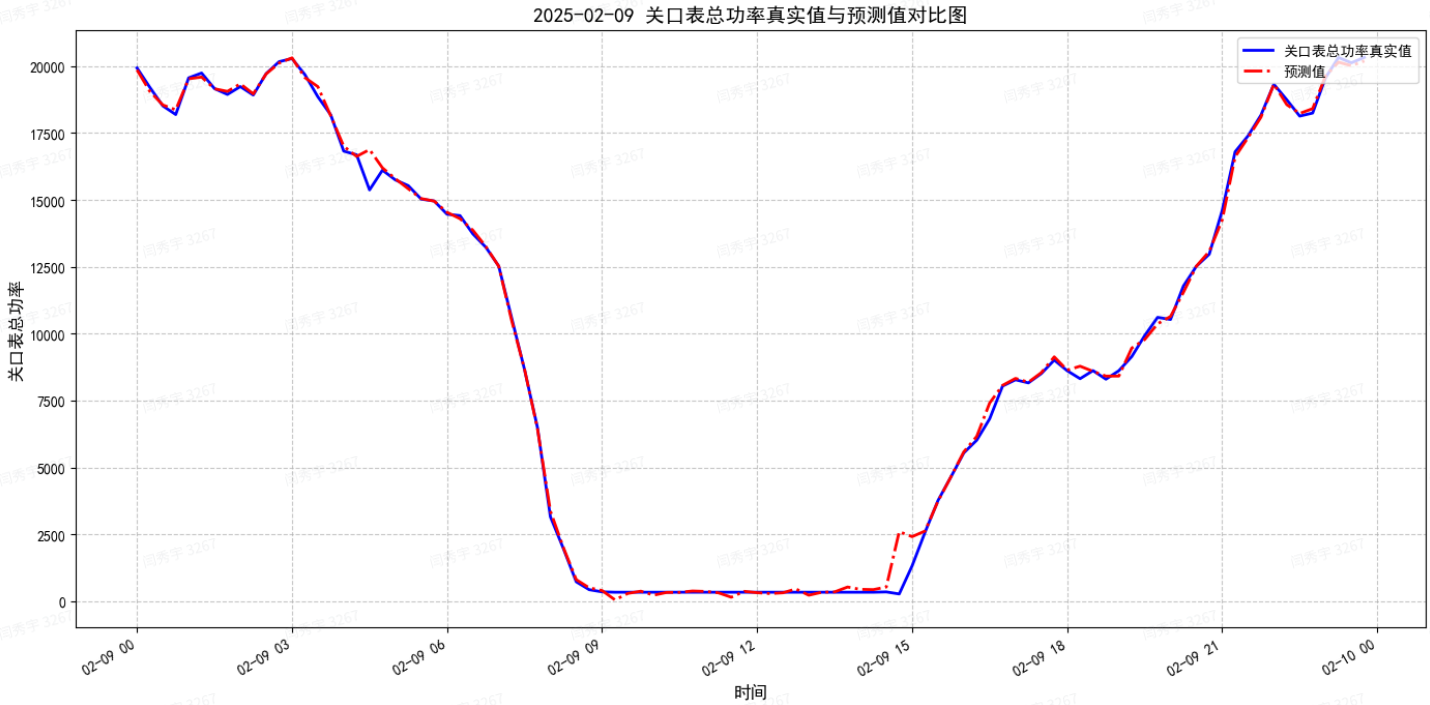

- 放假后的第一天工作日：2025年2月6日

```
日期: 2025-02-06
决定系数 R²: 0.9907
均方根误差RMSE: 417.8269
```

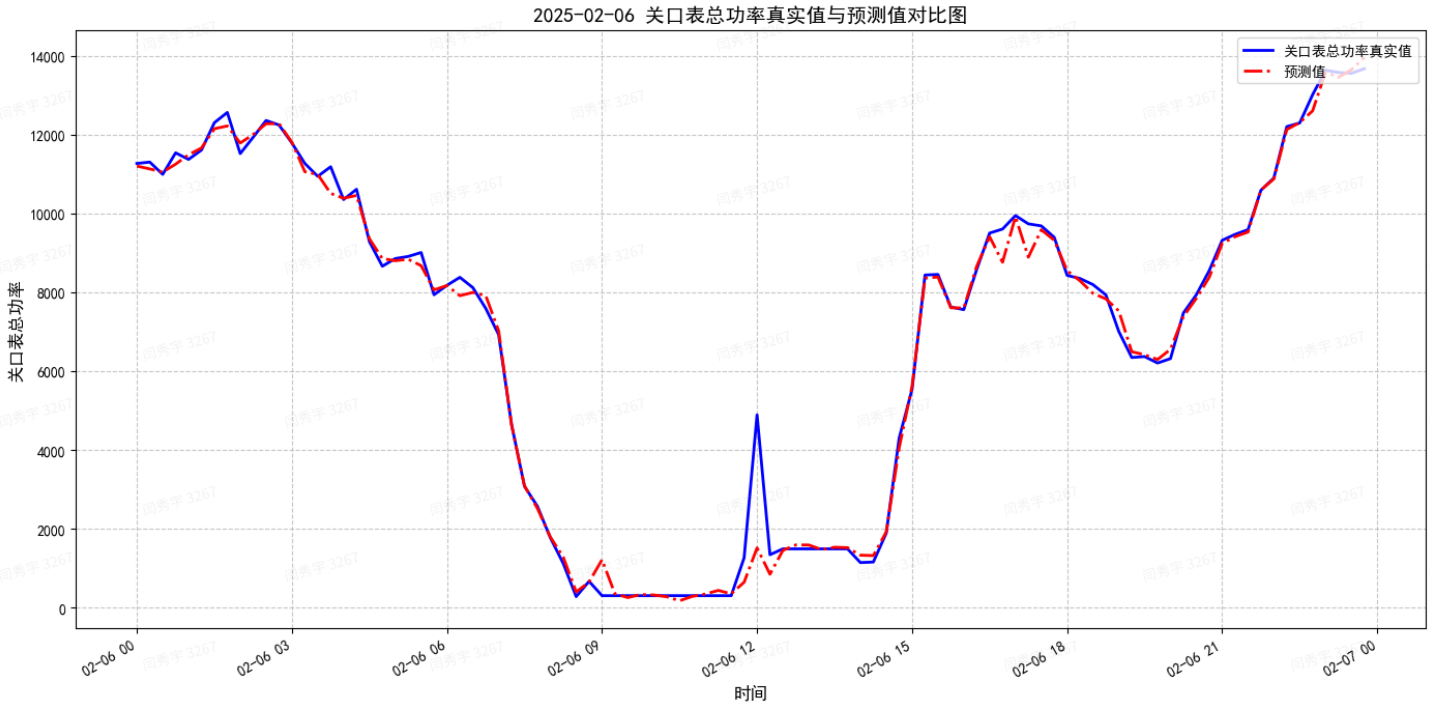

1.2.2 部分放假

- 正常部分放假：2025年1月24日

```
日期: 2025-01-24
决定系数 R²: 0.9514
均方根误差RMSE: 221.7423
```

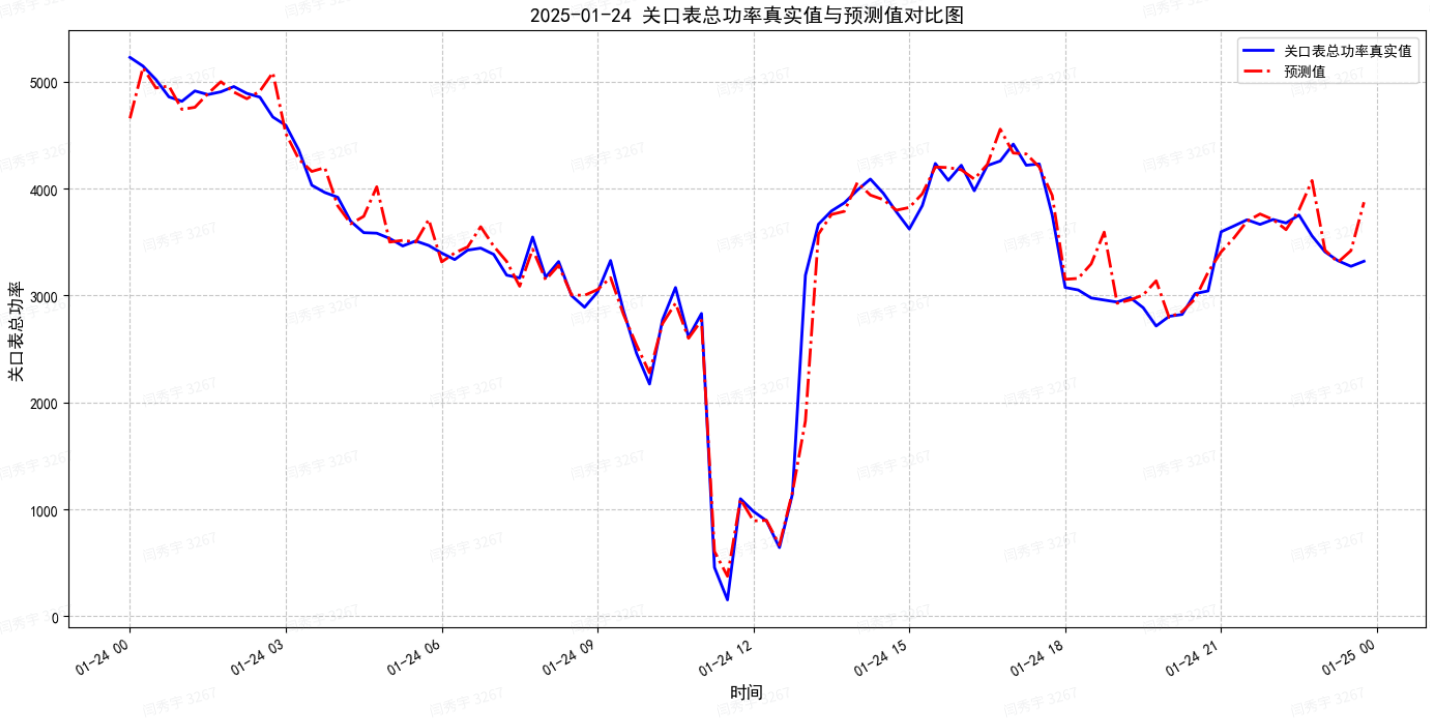

- 工作日后的第一天部分放假：2025年1月22日

```
日期: 2025-01-22
决定系数 R²: 0.9931
均方根误差RMSE: 241.0983
```

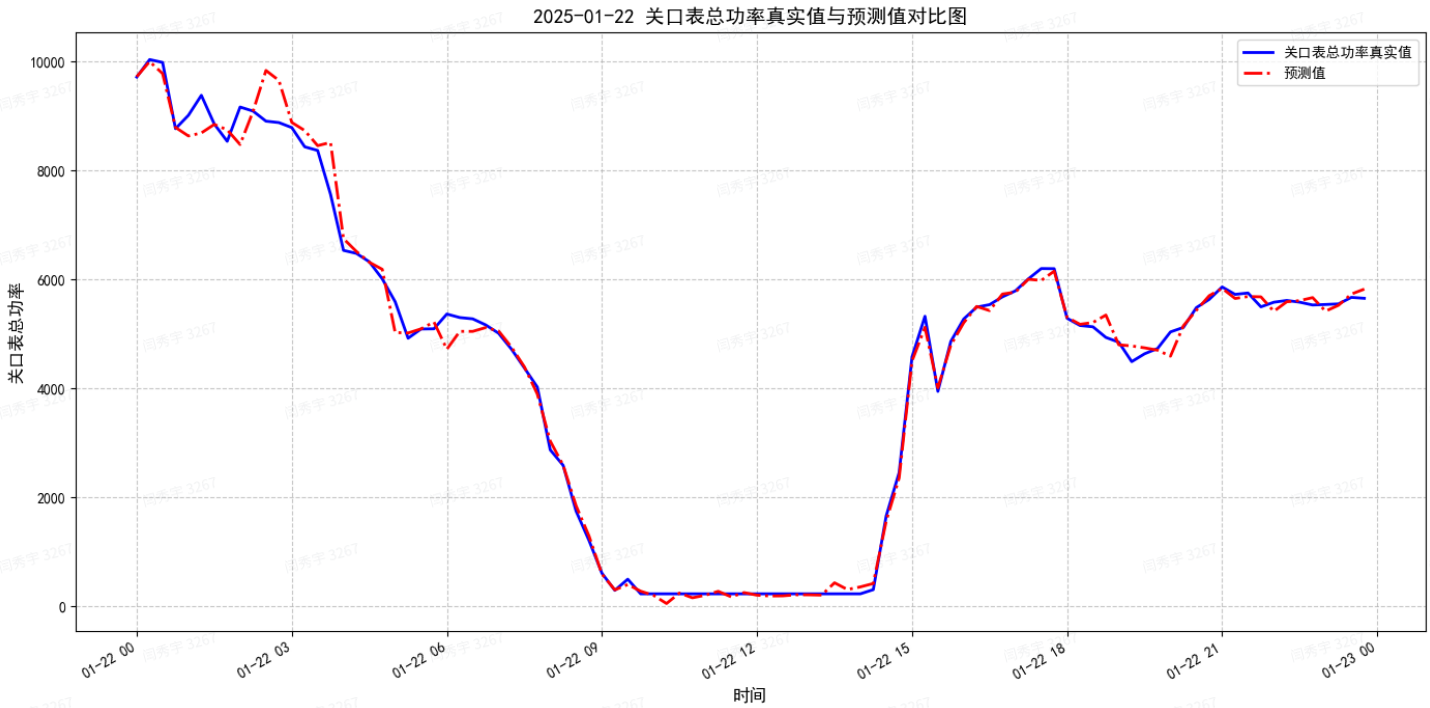

1.2.3 放假

- 正常放假：2025年2月5日

```
日期: 2025-02-05
决定系数 R²: 0.9935
均方根误差RMSE: 206.1917
```

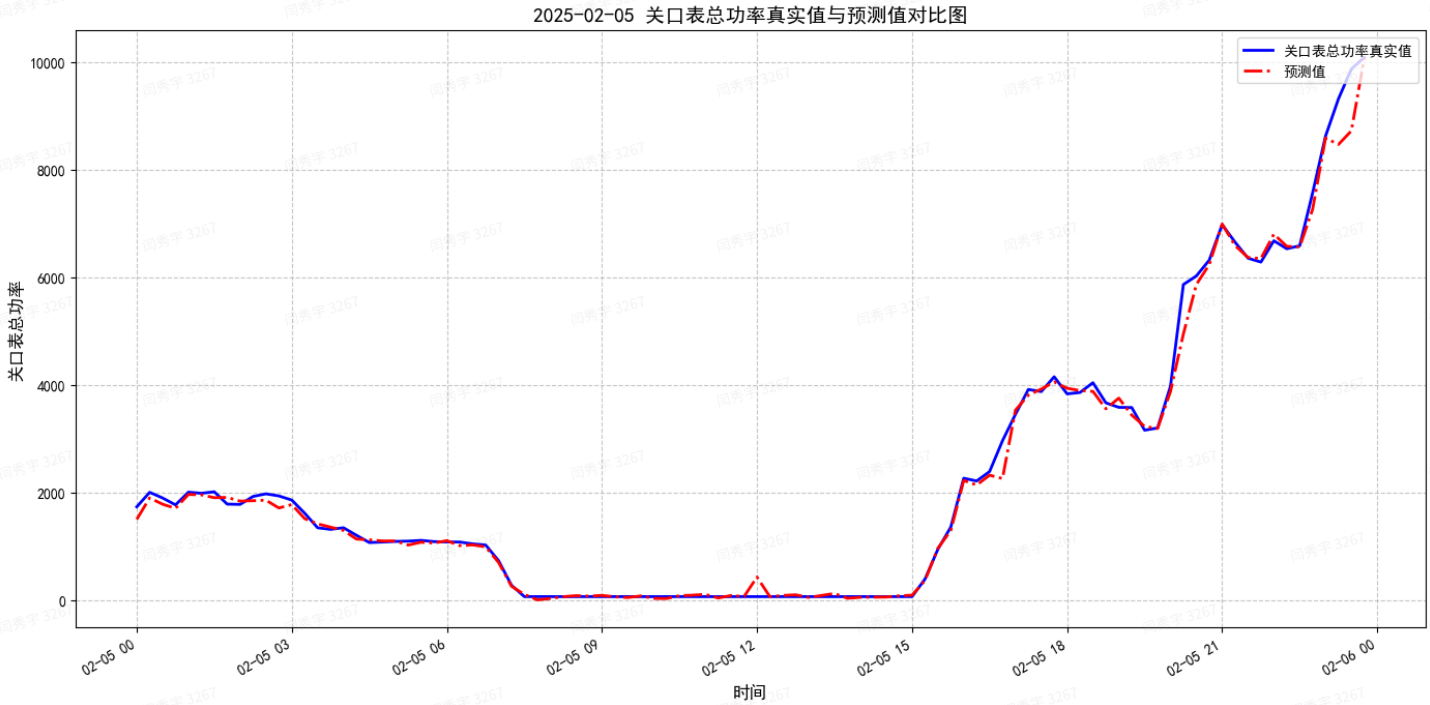

- 部分放假后的第一天放假：2025年1月28日

```
日期: 2025-01-28
决定系数 R²: 0.9797
均方根误差RMSE: 81.1043
```

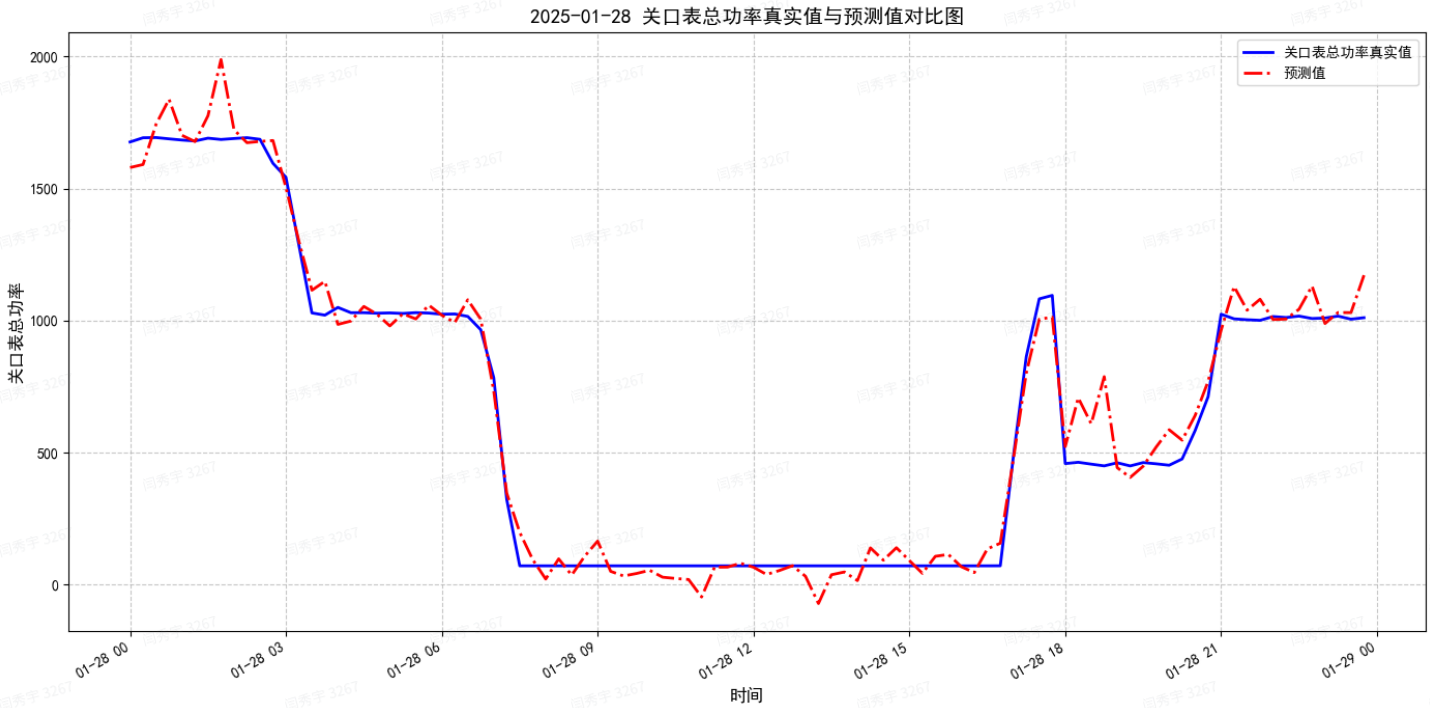

2. 预测未来一天（96个点）

2.1 光伏发电功率

2.1.1 2024年11月22日

```
日期: 2024-11-22
决定系数R²: 0.9534
均方根误差RMSE: 306.0768
```

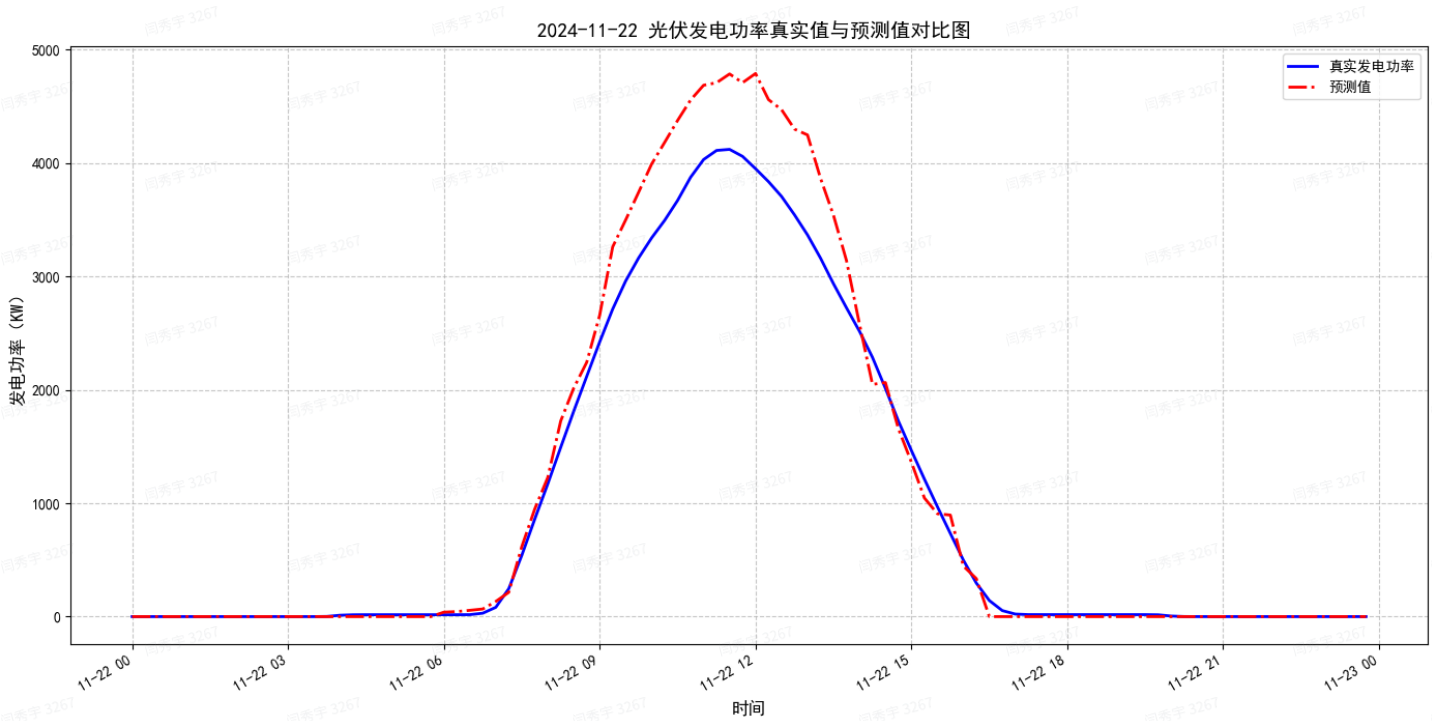

- 4:00~7:00

```
时间: 2024-11-22 4-7
决定系数R²: -30.2526
均方根误差RMSE: 22.6902
```

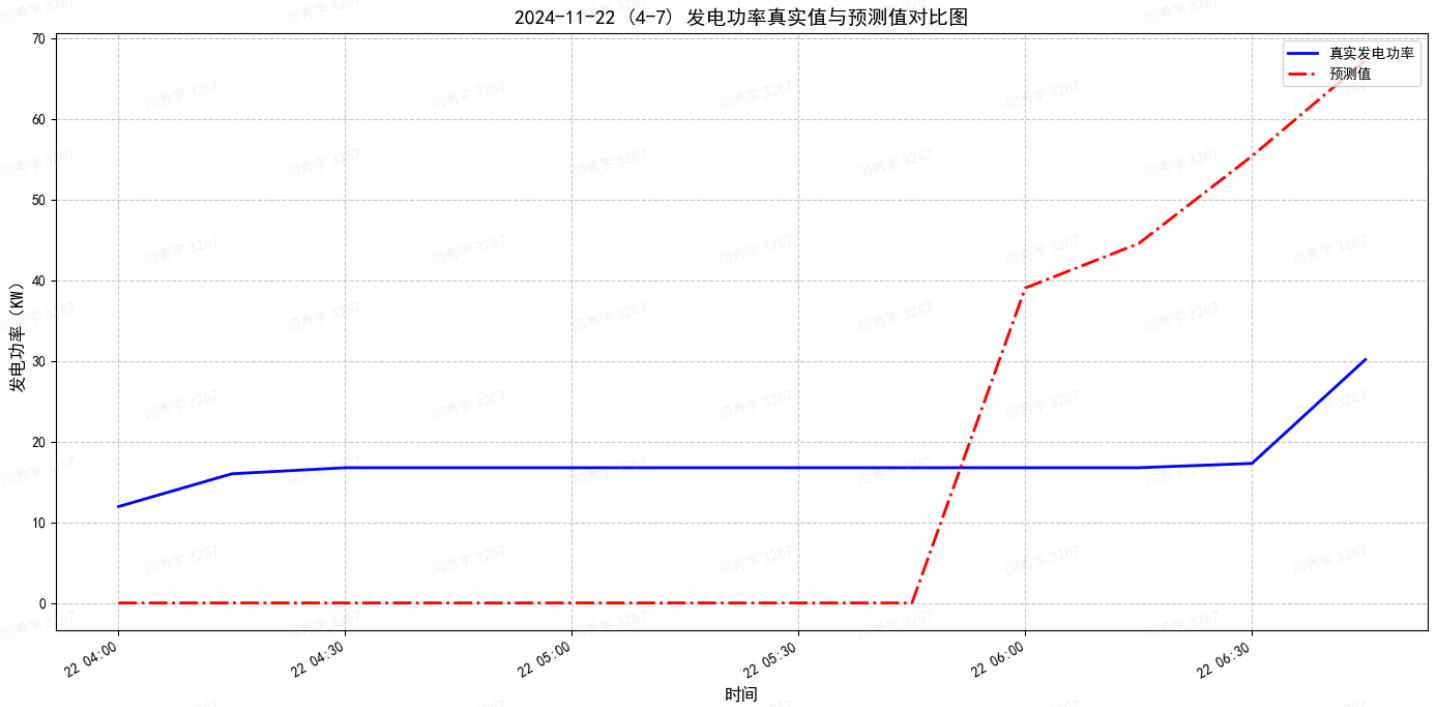

- 7:00~16:00

```
时间: 2024-11-22 7-16
决定系数R²: 0.8324
均方根误差RMSE: 498.7857
```

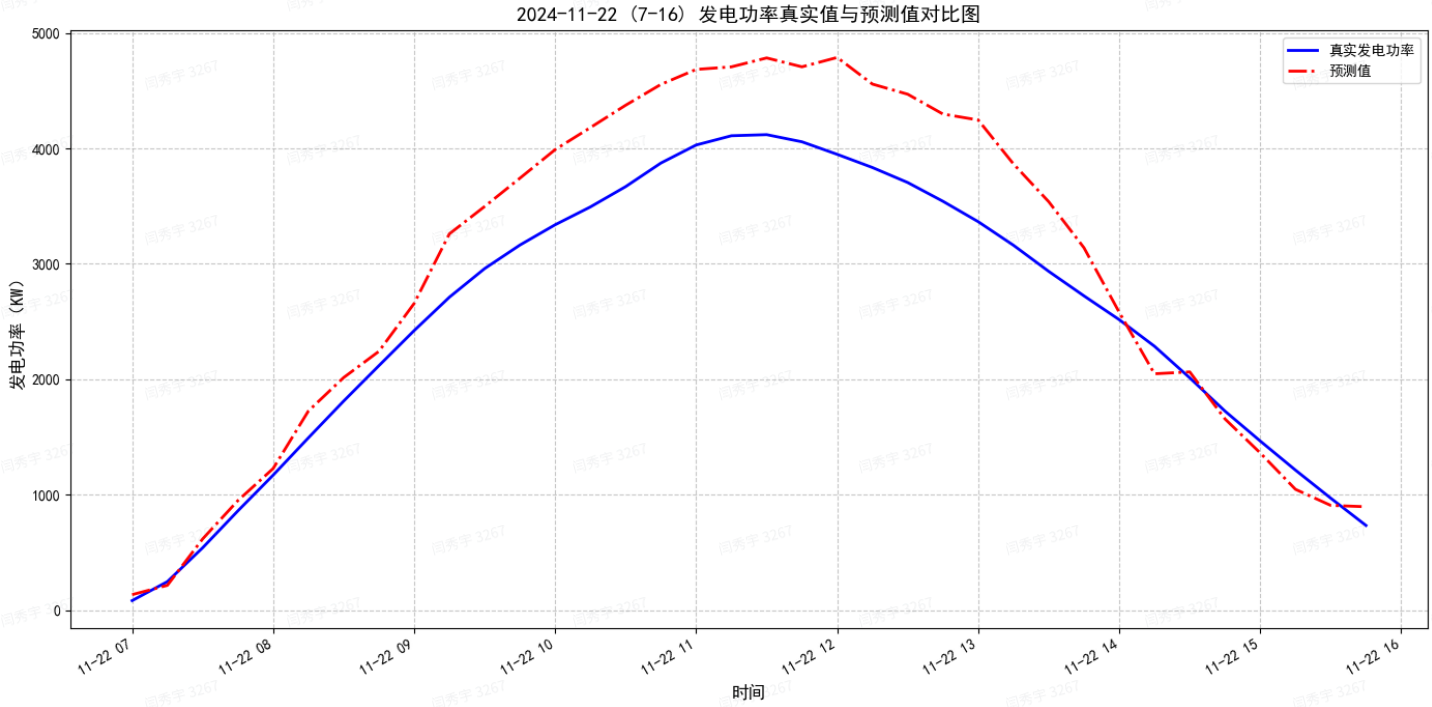

- 16:00~20:00

```
时间: 2024-11-22 16-20
决定系数R²: 0.8861
均方根误差RMSE: 44.0350
```

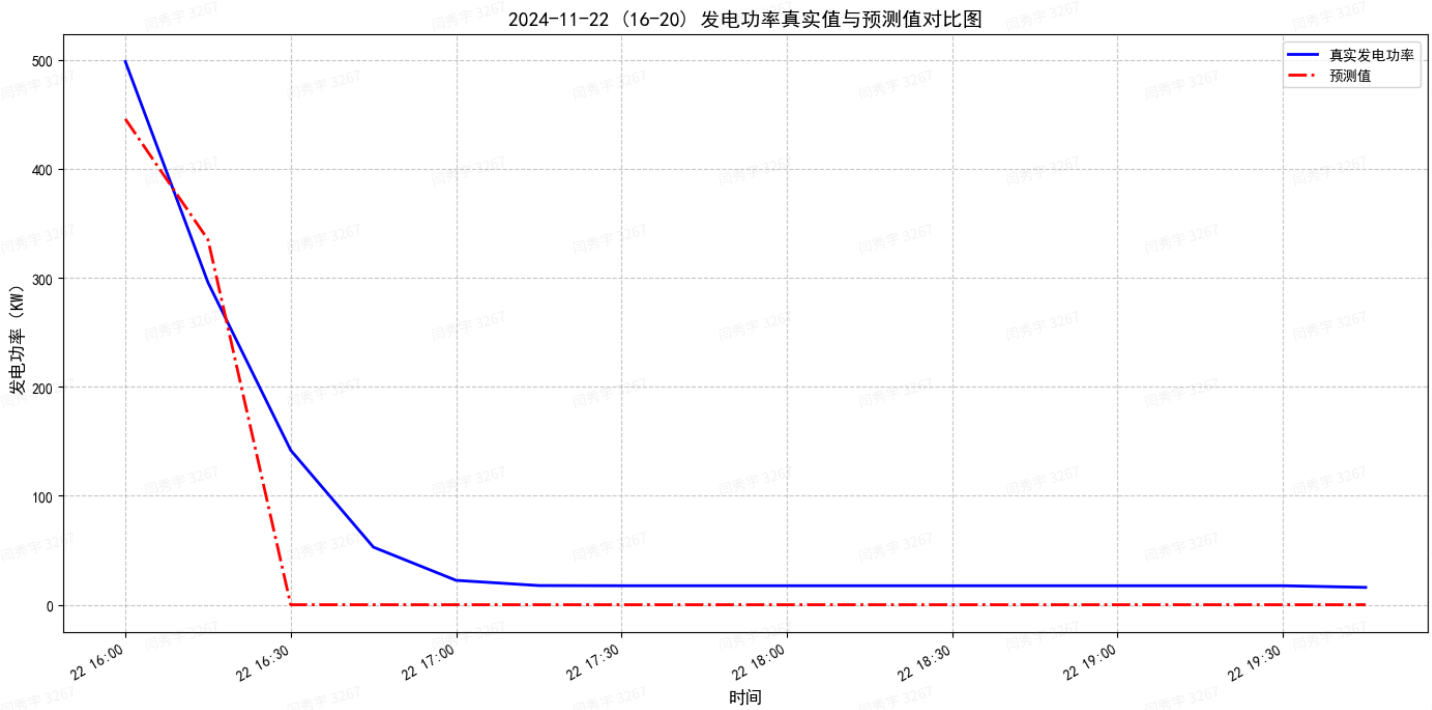

2.1.2 2024年11月27日

```
日期: 2024-11-27
决定系数R²: 0.9402
均方根误差RMSE: 351.6336
```

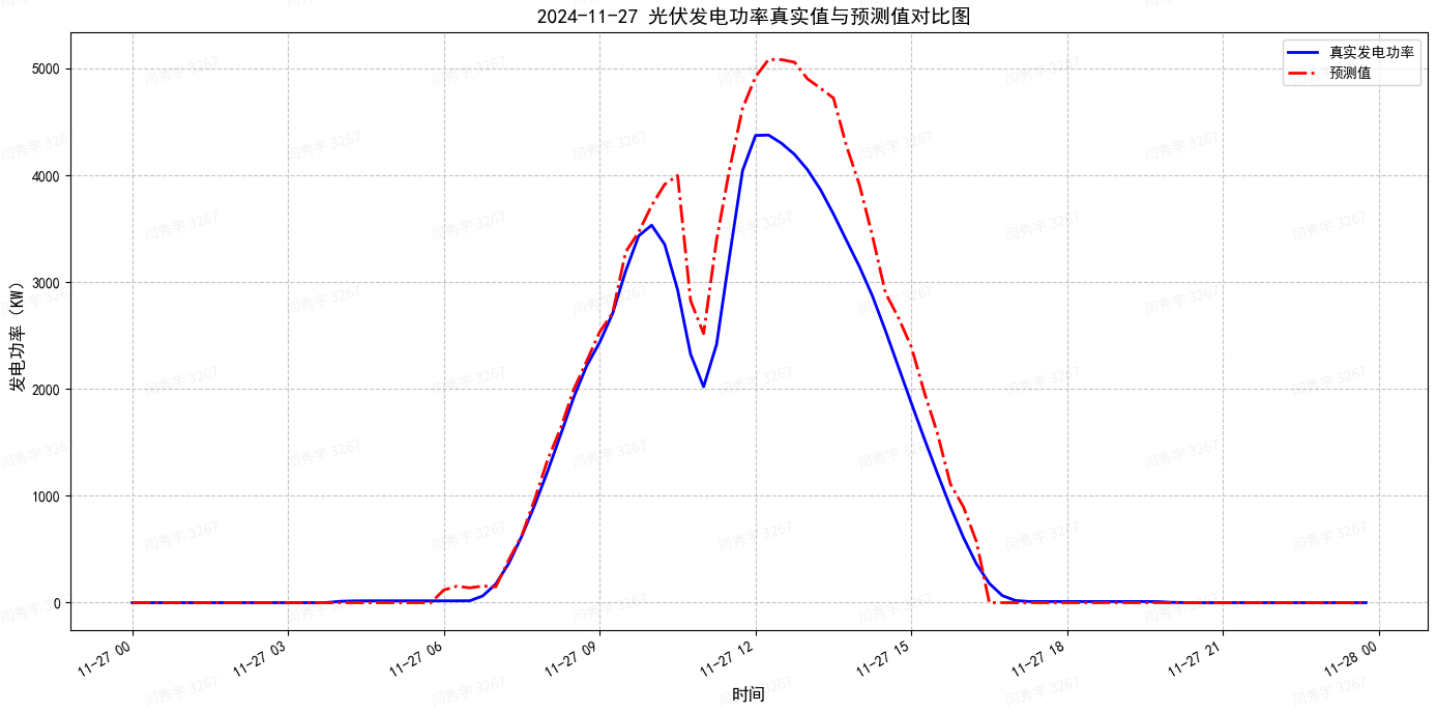

- 4:00~7:00

```
时间: 2024-11-27 4-7
决定系数R²: -25.6991
均方根误差RMSE: 67.2942
```

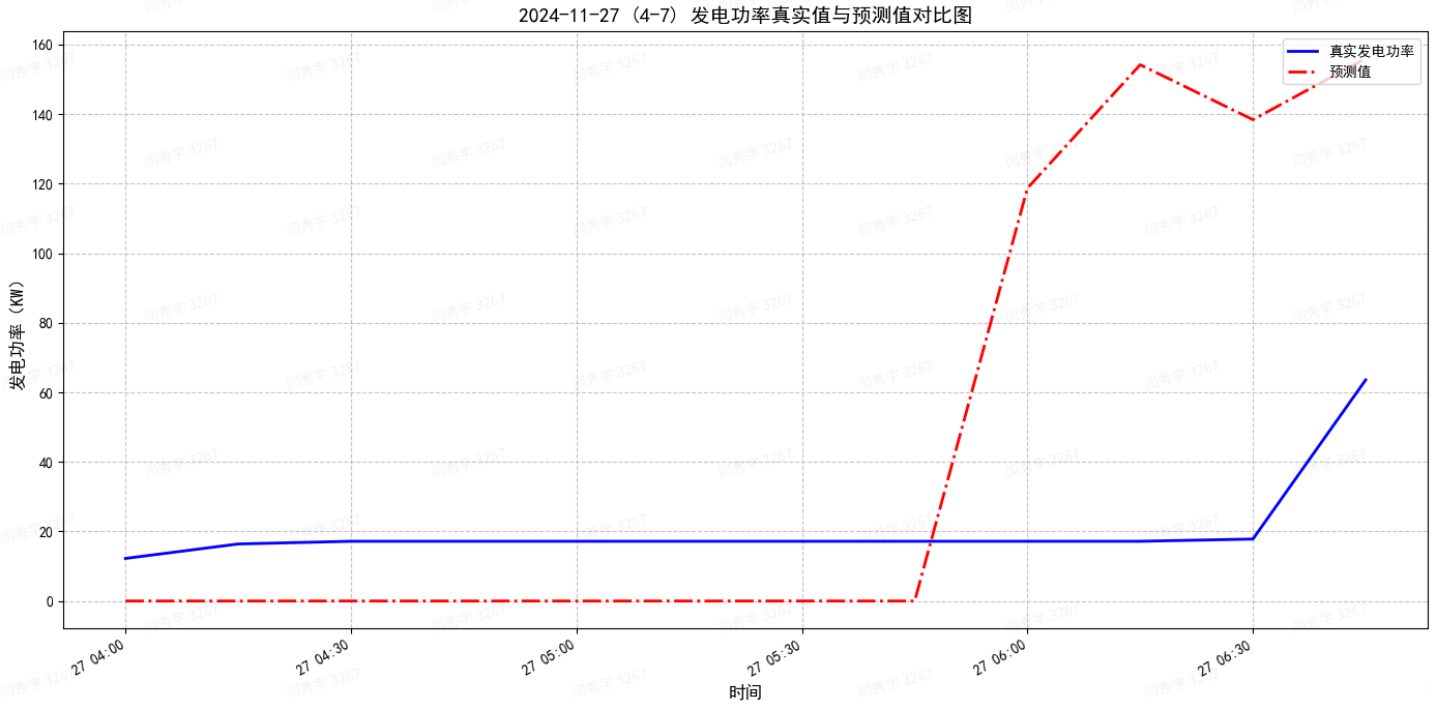

- 7:00~16:00

```
时间: 2024-11-27 7-16
决定系数R²: 0.7705
均方根误差RMSE: 568.8949
```

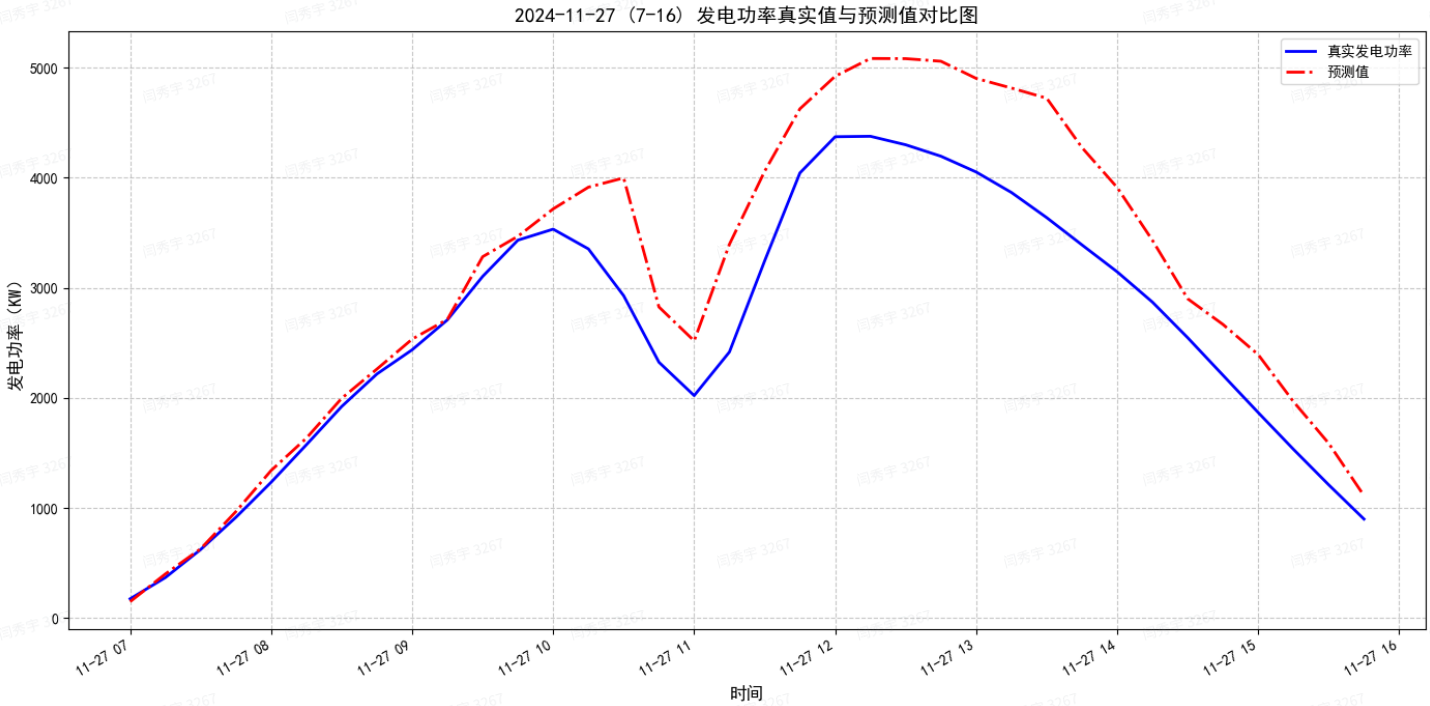

- 16:00~20:00

```
时间: 2024-11-27 16-20
决定系数R²: 0.6168
均方根误差RMSE: 101.4251
```

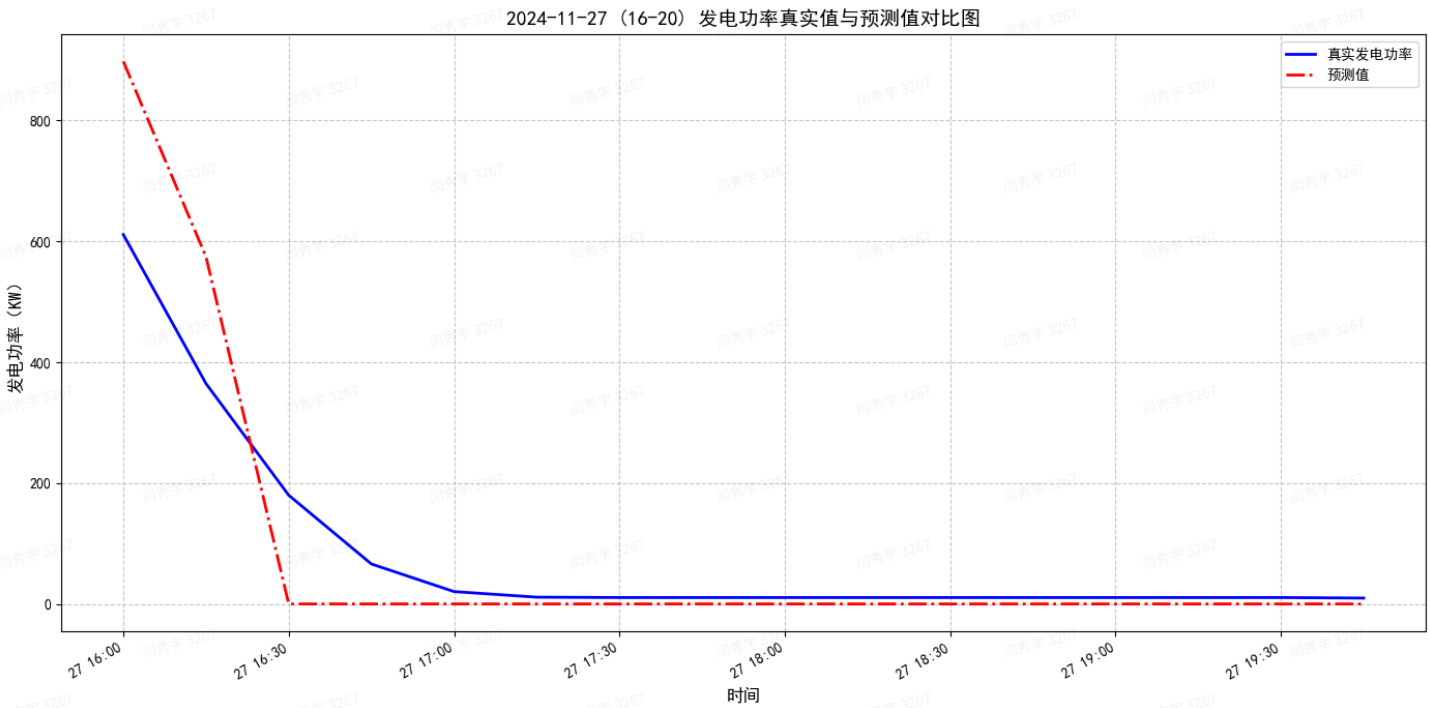

2.1.3 2024年11月29日

```
日期: 2024-11-29
决定系数R²: 0.9388
均方根误差RMSE: 398.8569
```

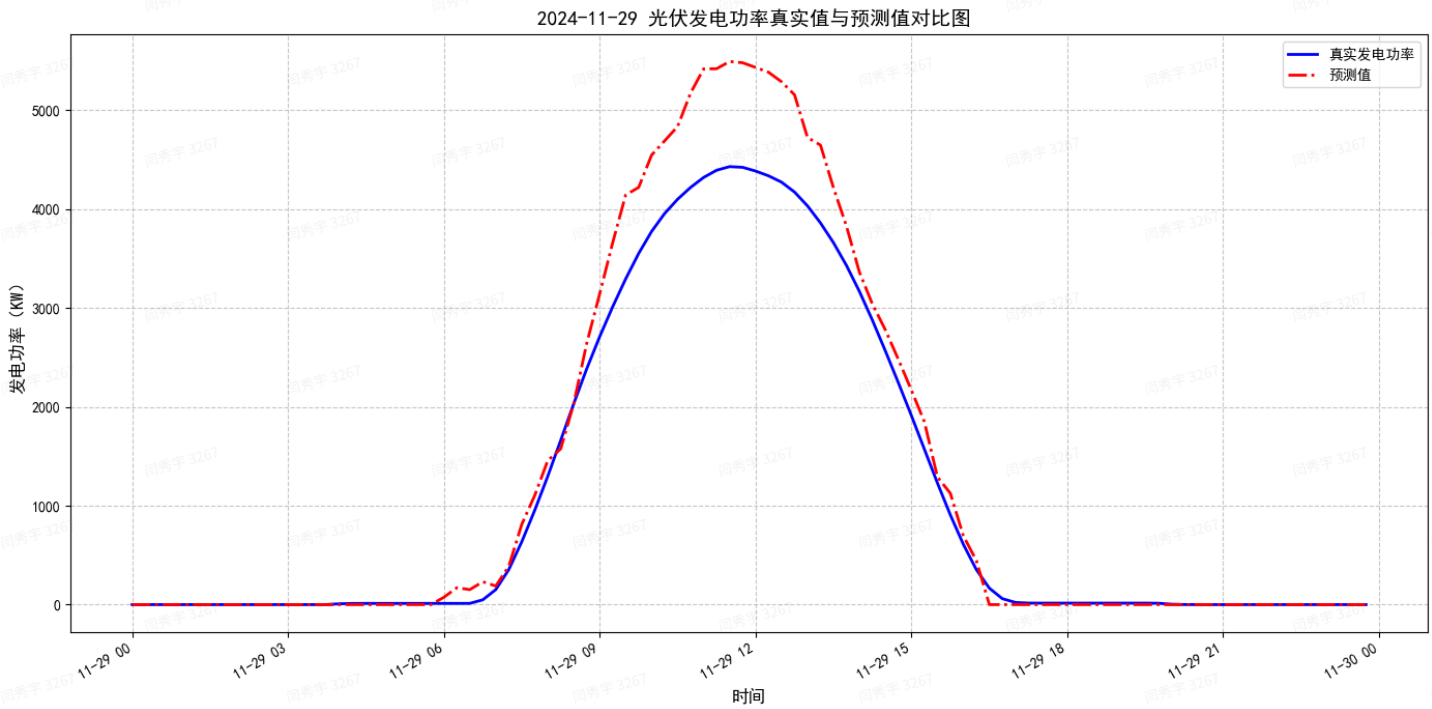

- 4:00~7:00

```
时间: 2024-11-29 4-7
决定系数R²: -66.1119
均方根误差RMSE: 83.0000
```

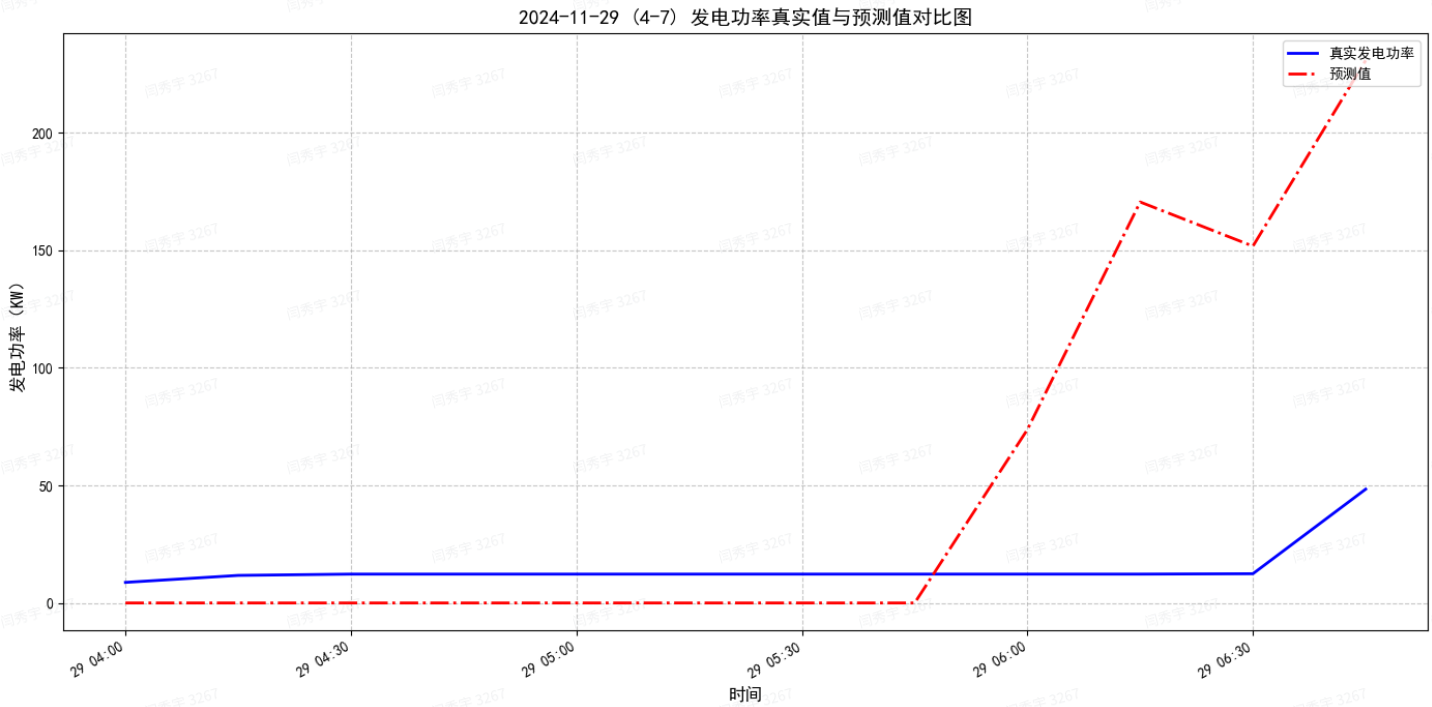

- 7:00~16:00

```
时间: 2024-11-29 7-16
决定系数R²: 0.7619
均方根误差RMSE: 648.4904
```

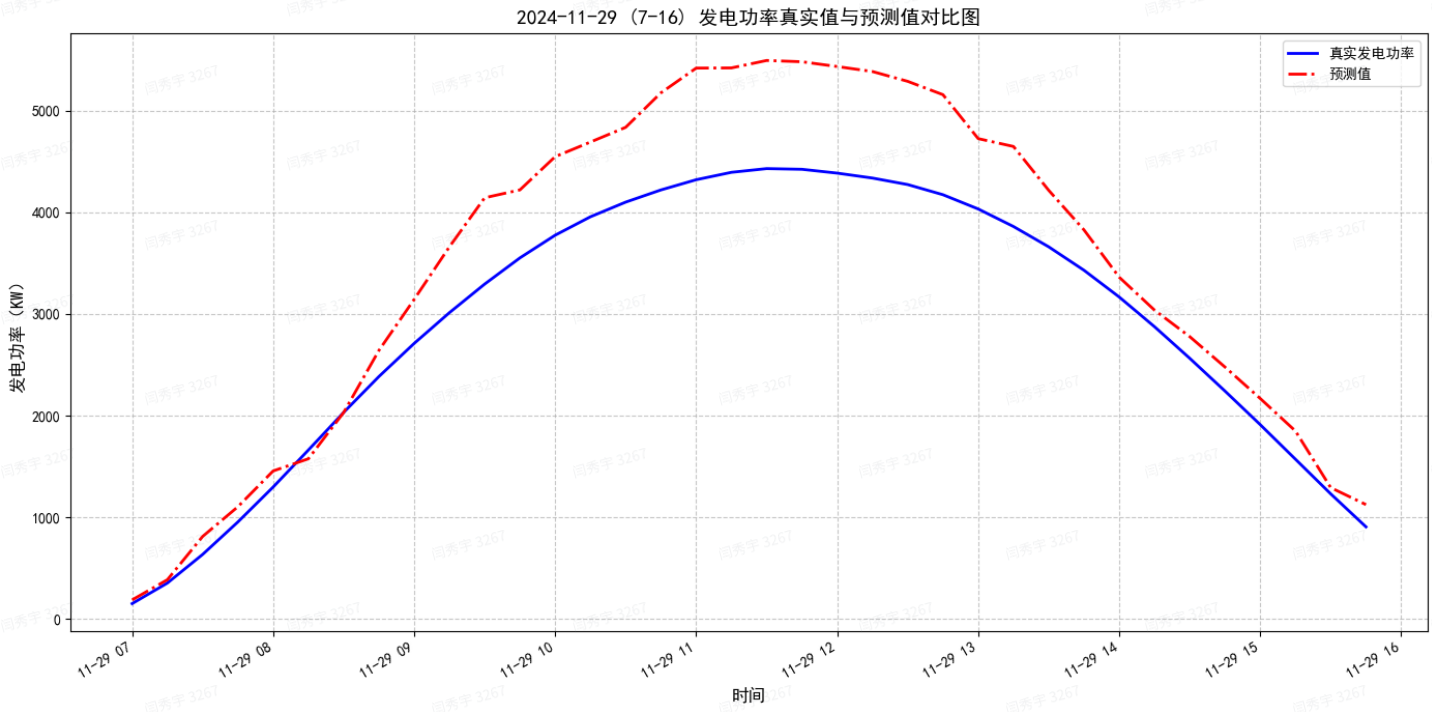

- 16:00~20:00

```
时间: 2024-11-29 16-20
决定系数R²: 0.8781
均方根误差RMSE: 56.0203
```

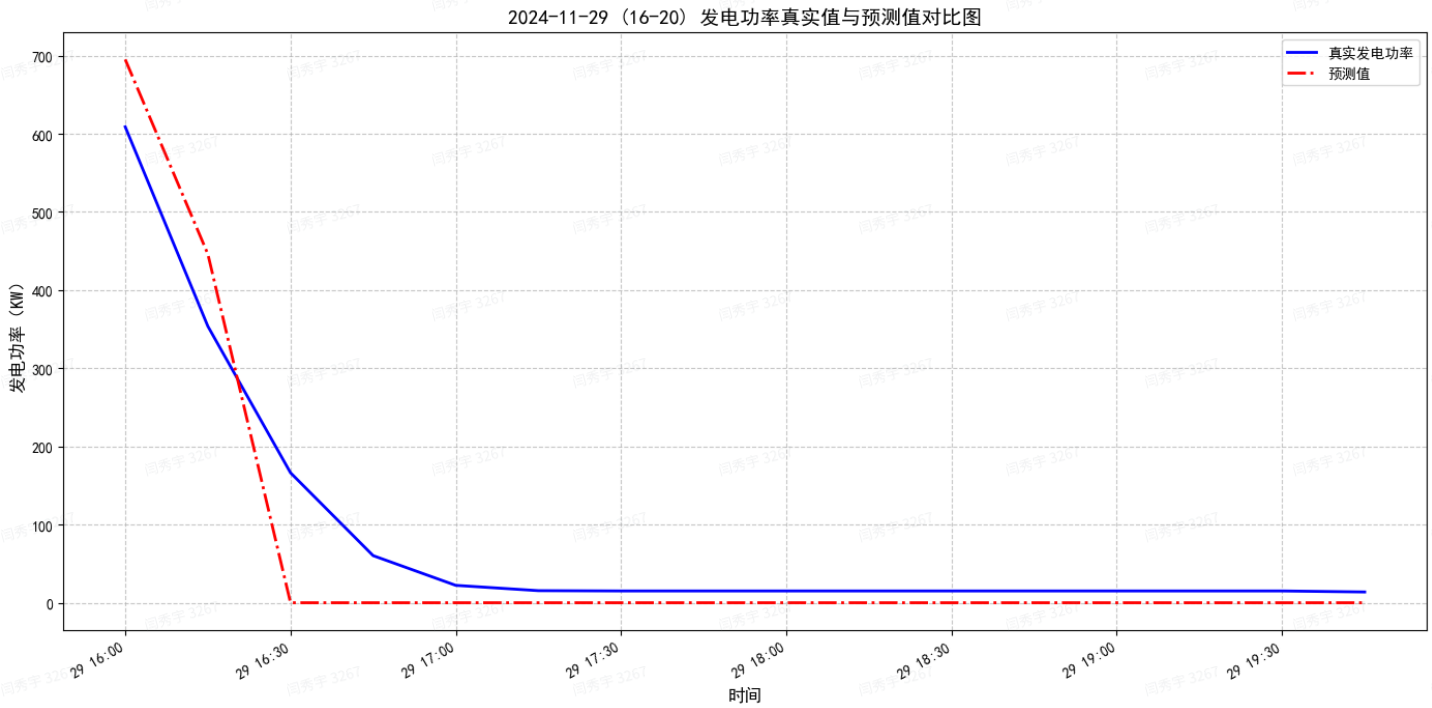

2.2 工厂用电负荷

2.2.1 工作日

- 正常工作日：2025年2月9日

```
日期: 2025-02-09
决定系数 R²: 0.9552
均方根误差RMSE: 1594.3056
```

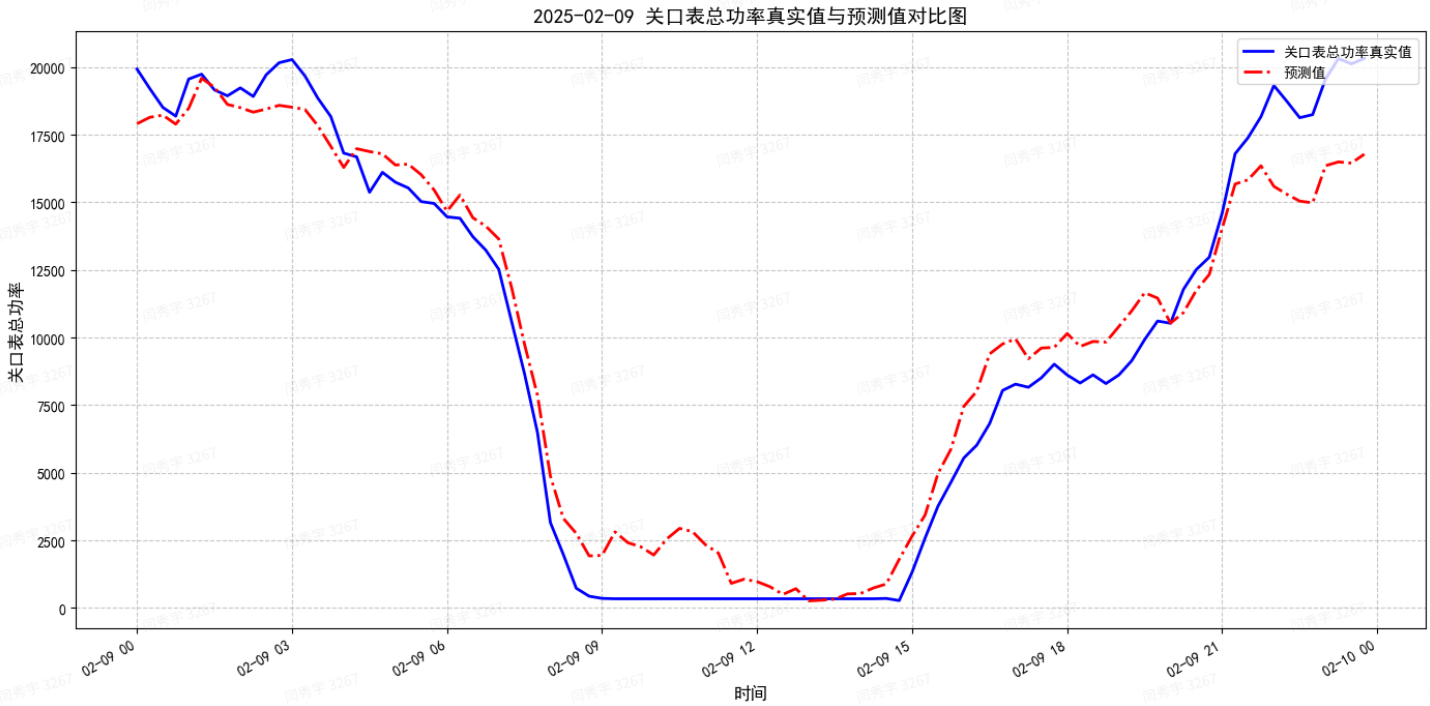

- 放假后的第一天工作日：2025年2月6日

```
日期: 2025-02-06
决定系数 R²: 0.3809
均方根误差RMSE: 3414.4431
```

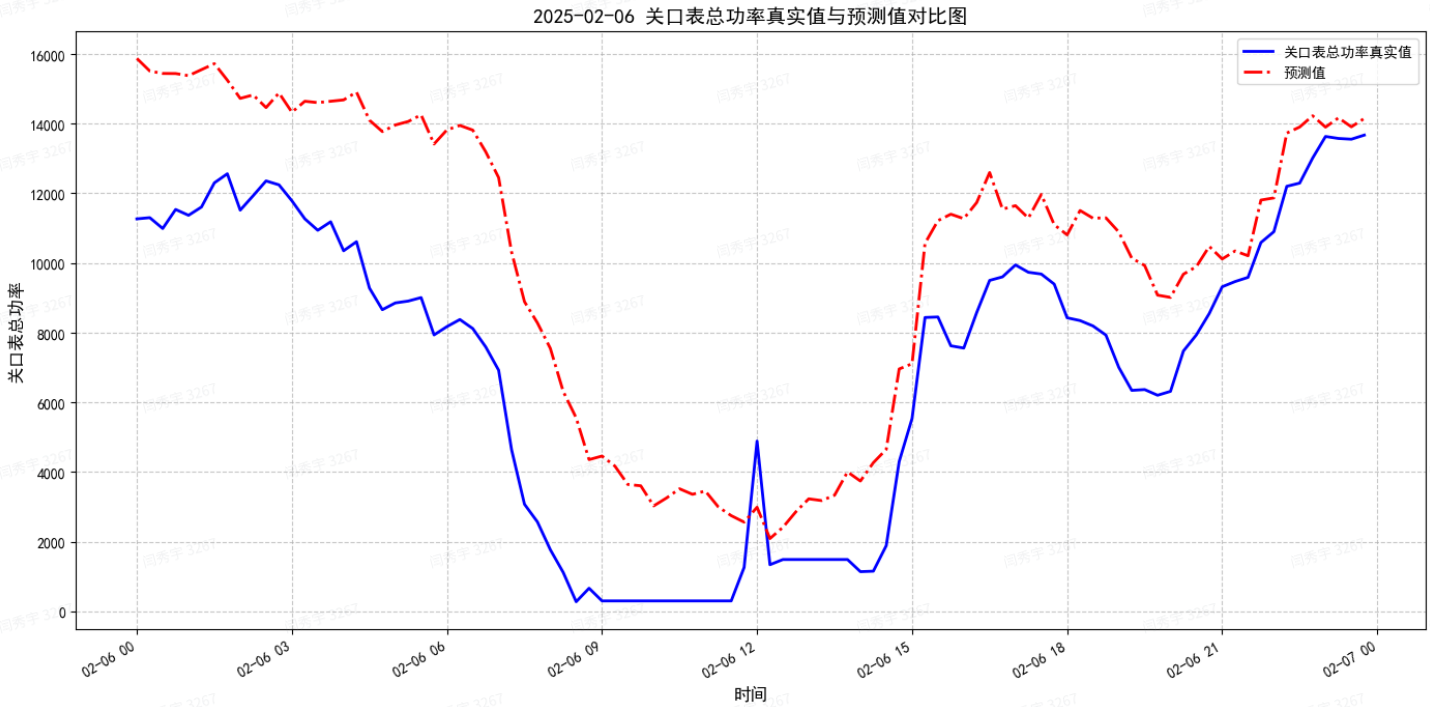

2.2.2 部分放假

- 正常部分放假：2025年1月24日

```
日期: 2025-01-24
决定系数 R²: -61.3169
均方根误差RMSE: 7938.6462
```

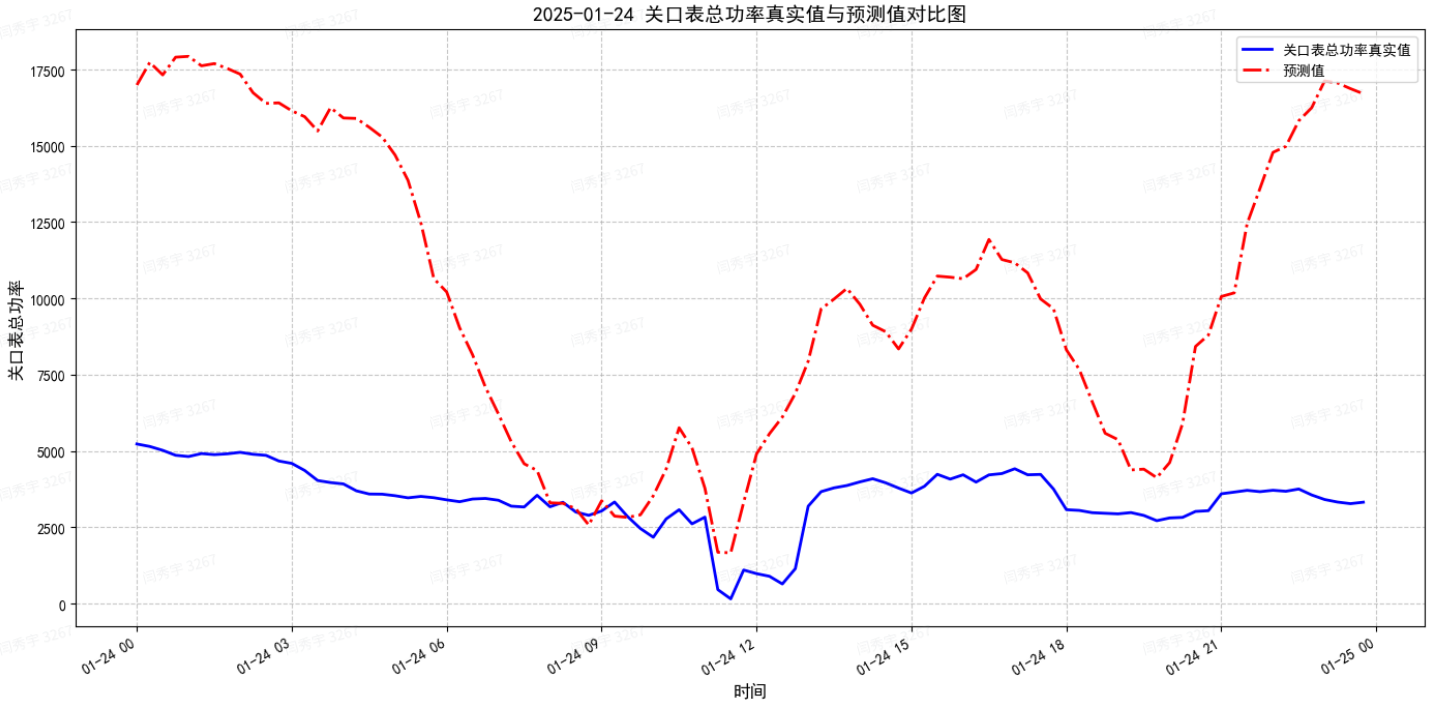

- 工作日后的第一天部分放假：2025年1月22日

```
日期: 2025-01-22
决定系数 R²: -2.3161
均方根误差RMSE: 5285.9214
```

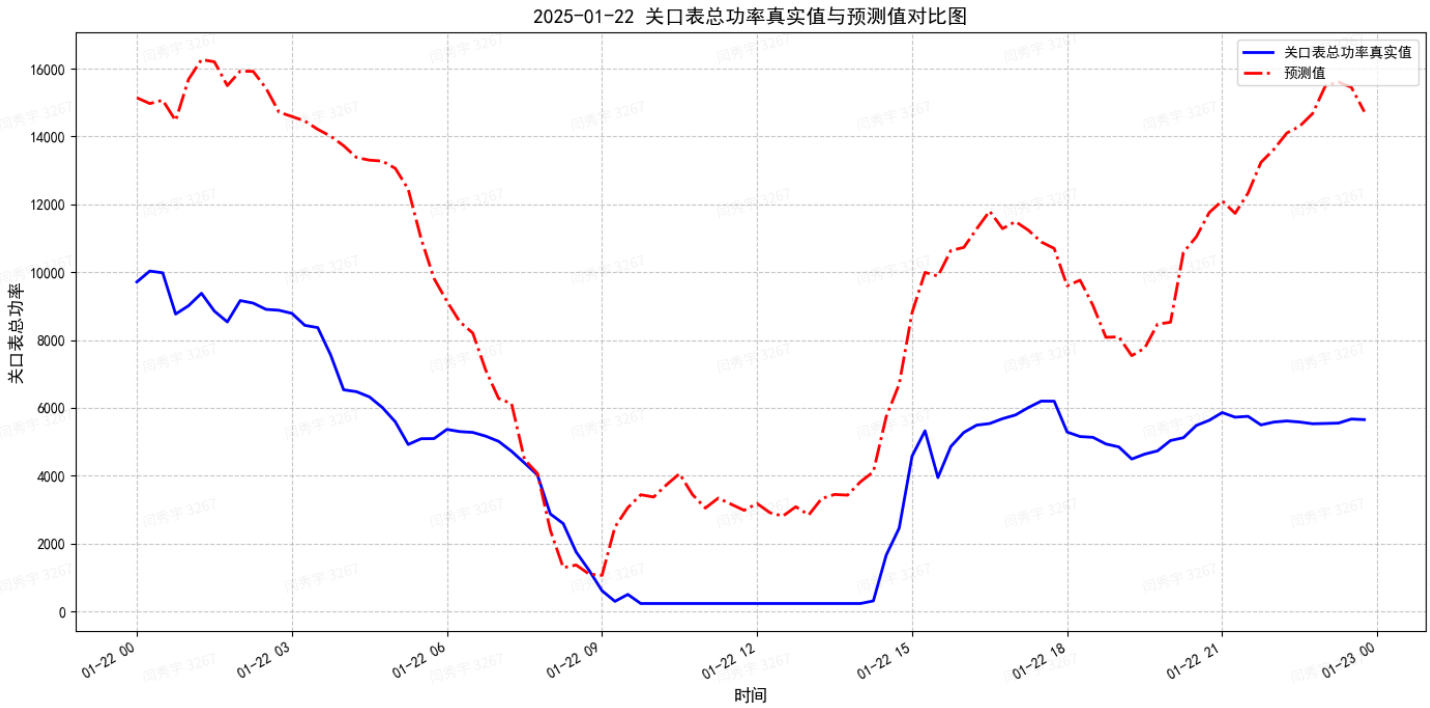

2.2.3 放假

- 正常放假：2025年2月5日

```
日期: 2025-02-06
决定系数 R²: 0.3809
均方根误差RMSE: 3414.4431
```

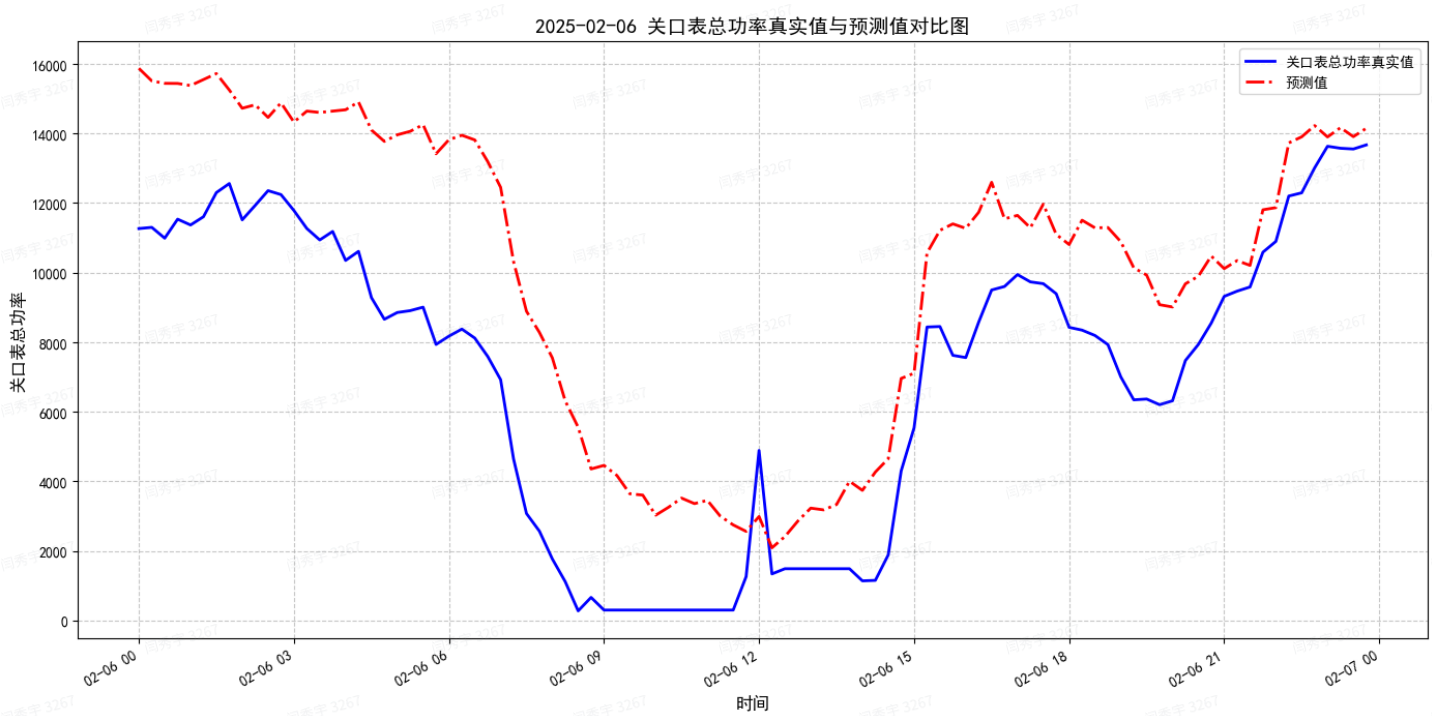

- 部分放假后的第一天放假：2025年1月28日

```
日期: 2025-01-28
决定系数 R²: -185.7930
均方根误差RMSE: 7788.7624
```

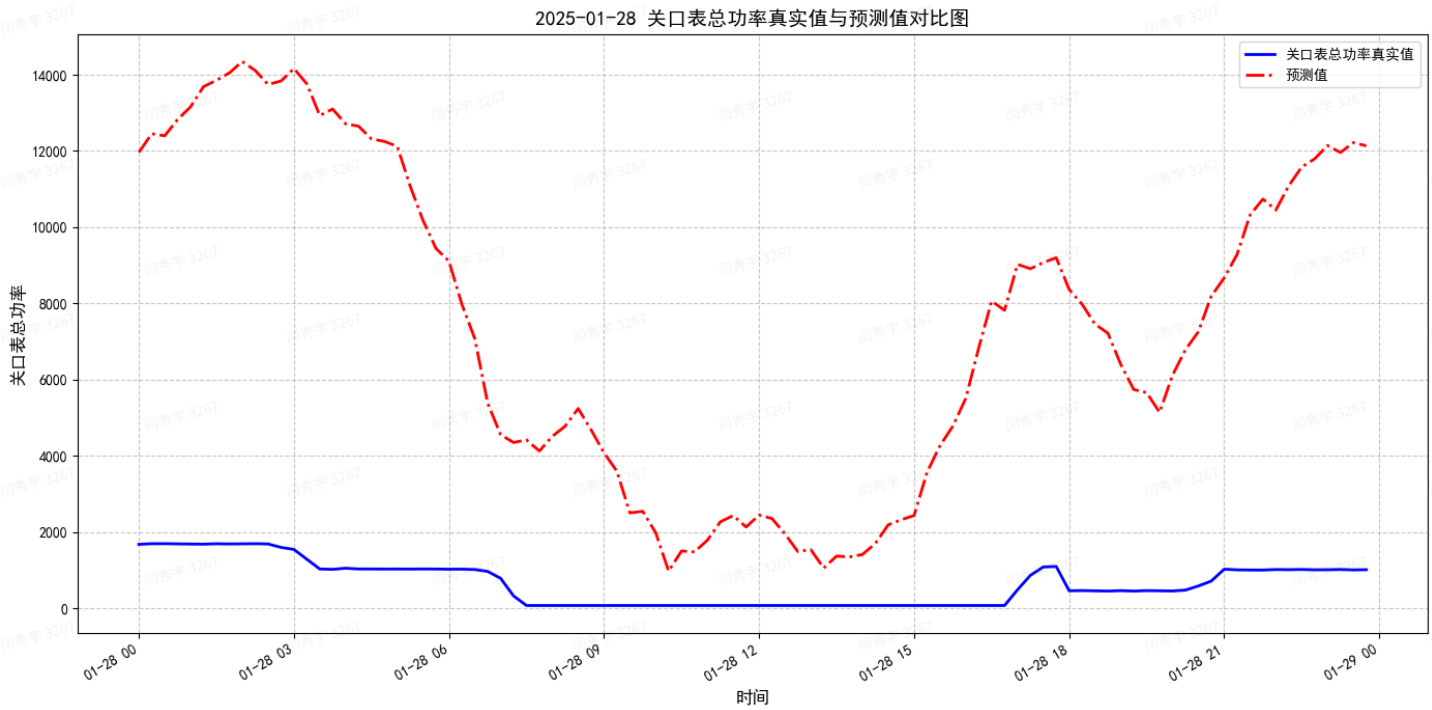

六、总结

- 光伏发电功率预测汇总
  - 预测未来一小时（4个点）

	整天		4:00~7:00		7:00~16:00		16:00~20:00	
	决定系数R2	均方根误差RMSE	决定系数R2	均方根误差RMSE	决定系数R2	均方根误差RMSE	决定系数R2	均方根误差RMSE
11月22日	0.9981	61.6671	-50.4409	29.1105	0.9940	94.1453	0.8686	47.2990
11月27日	0.9889	151.4738	-1.7539	21.6125	0.9634	227.1846	0.2109	145.5535
11月29日	0.9898	162.7947	-2.1942	18.1075	0.9613	261.4751	0.8083	70.2486

  - 预测未来一天（96个点）

	整天		4:00~7:00		7:00~16:00		16:00~20:00	
	决定系数R2	均方根误差RMSE	决定系数R2	均方根误差RMSE	决定系数R2	均方根误差RMSE	决定系数R2	均方根误差RMSE
11月22日	0.9534	306.0768	-30.2526	22.6902	0.8324	498.7857	0.8861	44.0350
11月27日	0.9402	351.6336	-25.6991	67.2942	0.7705	568.8949	0.6168	101.4251
11月29日	0.9138	470.6118	-66.1119	83.0000	0.7619	648.4904	0.8781	56.0203

- 用电负荷预测汇总
  - 预测未来一小时（4个点）

	决定系数R2	均方根误差RMSE	描述
2月9日	0.9980	335.6724	正常工作日
2月6日	0.9907	417.8269	放假后的第一天工作日
1月24日	0.9514	221.7423	正常部分放假
1月22日	0.9931	241.0983	工作日后的第一天部分放假

2月5日	0.9935	206.1917	正常放假
1月28日	0.9797	81.1043	部分放假后的第一天放假

- 预测未来一天（96个点）

	决定系数R2	均方根误差RMSE	描述
2月9日	0.9552	1594.3056	正常工作日
2月6日	0.3809	3414.4431	放假后的第一天工作日
1月24日	-61.3169	7938.6462	正常部分放假
1月22日	-2.3161	5285.9214	工作日后的第一天部分放假
2月5日	-4.0566	5730.6582	正常放假
1月28日	-185.7930	7788.7624	部分放假后的第一天放假

- 光伏发电功率预测
  - 无论是日前还是日内，模型的预测精度均较高，然而日前模型在极值上的误差较大，将进一步考虑峰值优化的处理方法；
  - 依赖精确的气象数据（如辐照度、气温、降水等）以及合适的插值方法，高质量的天气数据决定了模型预测精度。
- 工厂用电负荷预测
  - 提供的数据中只有2025年1月28日~2025年2月5日为假期，训练数据中缺乏假期的真实值，因此混合训练时无法准确捕捉假期导致的负荷骤变；
  - 临近春节期间，工厂用电负荷将逐步降低，目前猜测可能为临近春节，工厂的开工计划逐步减少，但缺乏这部分的量化数据；
  - 建议考虑采用动态机制的方案来解决模型的误差问题，如工厂的放假计划提前得知后，日前不再使用模型进行预测，而是基于历史同期的数据进行映射，并加大日内预测模型的比重进行修正。